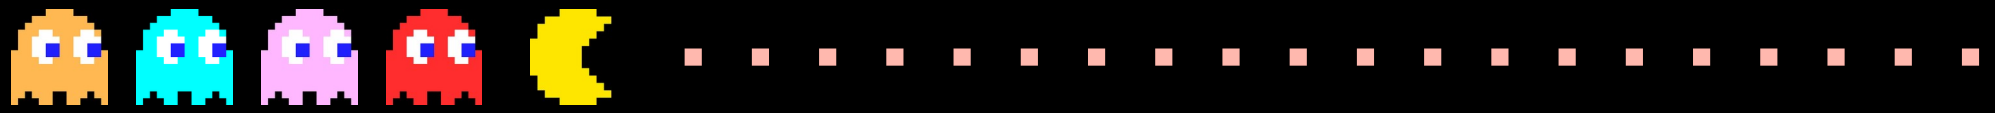
DATA WRANGLING · PROJET FINAL

VENTES MONDIALES DE JEUX VIDEO

1980 – 2016 · 16 598 jeux · Partie 1 : la base vgsales

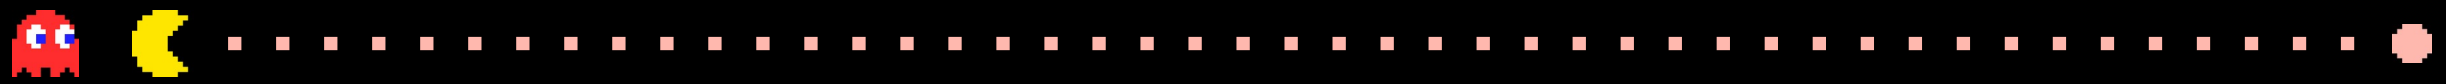


MODE COOP

1 EQUIPE · 2 BASES

PRESS START

© 2026 PGE3 · 23 OCTOBRE



MENU ➜ CHOISIS TON NIVEAU

Notre parcours

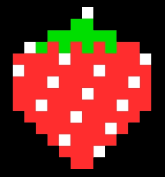
LEVEL 1



MISSION

Le contexte

LEVEL 2



PIPELINE

Du CSV à l'appli

LEVEL 3



NETTOYAGE

4 fantômes à manger

LEVEL 4



INSIGHTS

4 découvertes

LEVEL 5

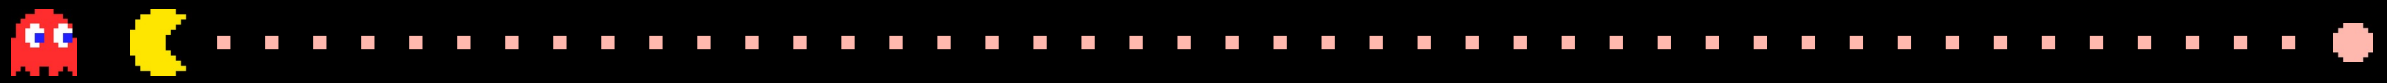


BOSS

Market Power Index



BONUS Niveau suivant : la BDD 2

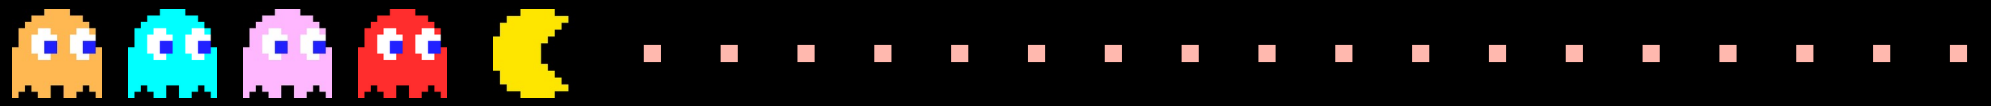




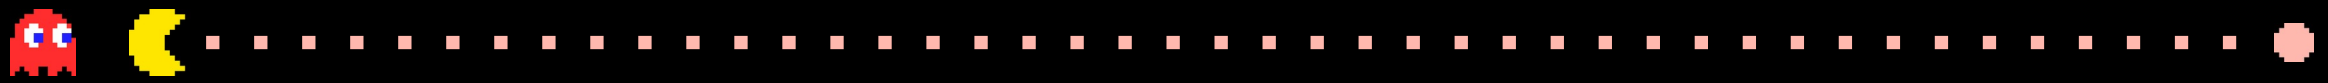
LEVEL 1

MISSION

Le contexte et la question de départ



READY!



LEVEL 1 ➜ MISSION

Le contexte



ROLE : DATA ANALYST

Qu'est-ce qui fait vendre un jeu vidéo ?

Nettoyer les ventes mondiales de jeux, explorer les tendances et en tirer des insights métier.

Source : VGChartz · ventes en millions d'exemplaires · Amérique du Nord, Europe, Japon, reste du monde

16 598

jeux dans le fichier

37 ANS

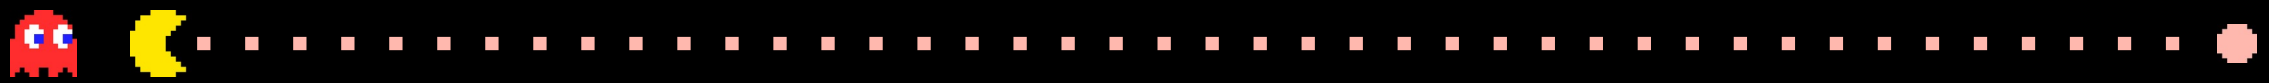
de 1980 à 2016

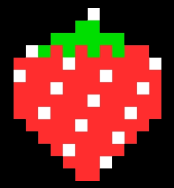
31

plateformes, de l'Atari 2600 à la PS4

8,9 MD

d'exemplaires vendus

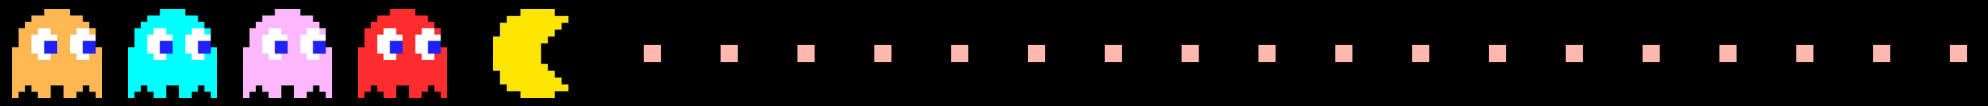




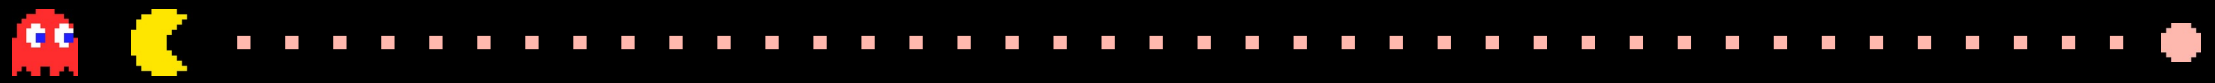
LEVEL 2

PIPELINE

Du fichier brut à l'appli interactive



READY!



LEVEL 2 ➜ PIPELINE

Du fichier brut à l'appli

01

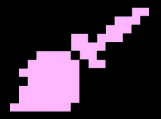


Données brutes

`vgsales.csv`

16 598 lignes

02



Nettoyage

`cleaning.py`

règles centralisées

03



Données propres

`vgsales_clean.csv`

16 326 jeux

04



Indicateurs

`indicators.py`

MPI · divergence

05



Restitution

`notebook + appli`

24 figures · 9 pages



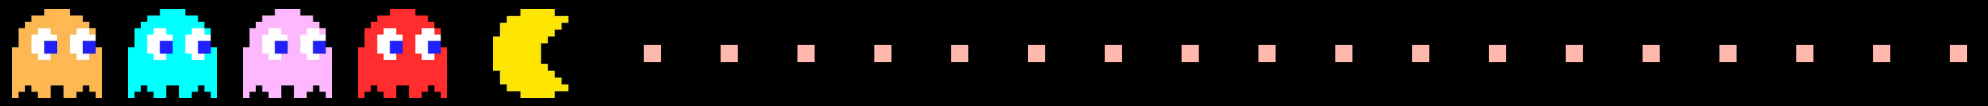
Un seul code de nettoyage pour le notebook ET l'appli. Un test (assert_frame_equal) garantit que les deux travaillent sur des données identiques.



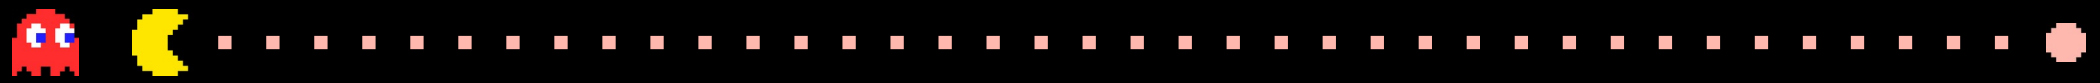
LEVEL 3

NETTOYAGE

4 fantômes cachés dans les données



READY!



LEVEL 3 ➜ NETTOYAGE

4 fantômes cachés dans les données

271
années manquantes

118 retrouvées grâce à une fiche jumelle, 153 supprimées

149
fiches « (JP sales) »

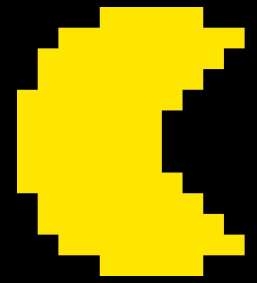
fusionnées : maximum par région, sans double comptage

10
dates impossibles

ex. un jeu DS daté de 1985 : 5 corrigées, 5 supprimées

261
éditeurs inconnus

58 vides + 203 « Unknown », regroupés en une seule catégorie



99,3%

des ventes conservées

16 598 → 16 326 jeux

11 239 titres uniques · 114 fiches fusionnées

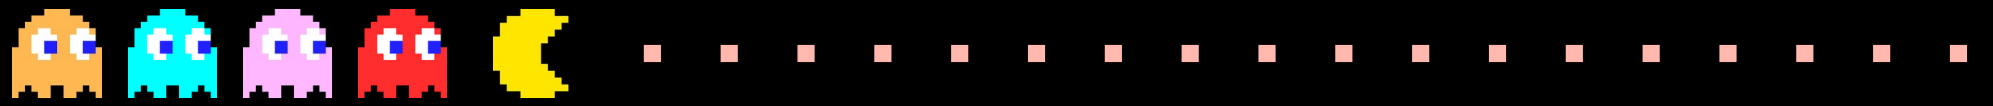
Chaque bug corrigé = un fantôme mangé



LEVEL 4

INSIGHTS

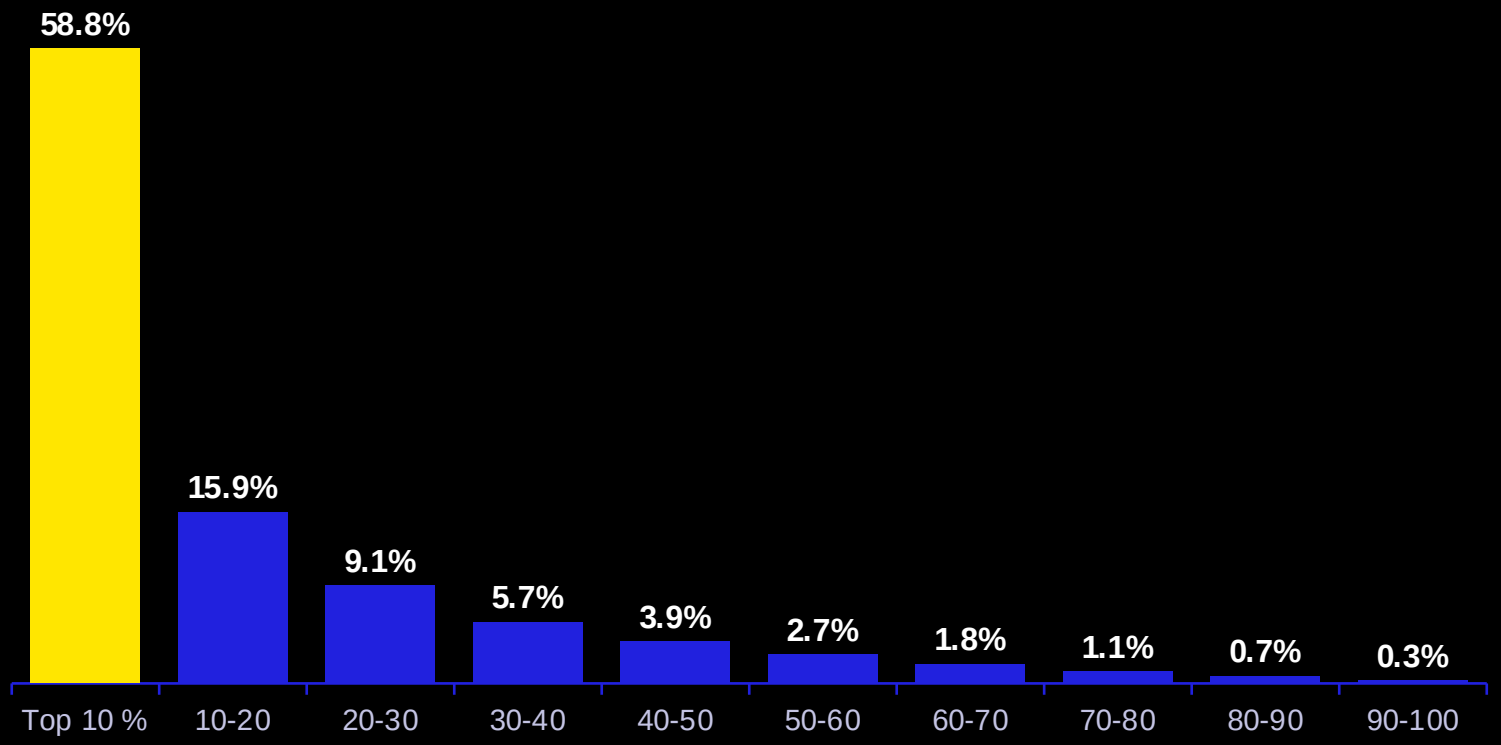
4 découvertes sur l'industrie du jeu vidéo



READY!

LEVEL 4 ➡ INSIGHT 1/4

Un marché de blockbusters



Jeux classés du plus vendu au moins vendu (tranches de 10 %)

10% des jeux

réalisent

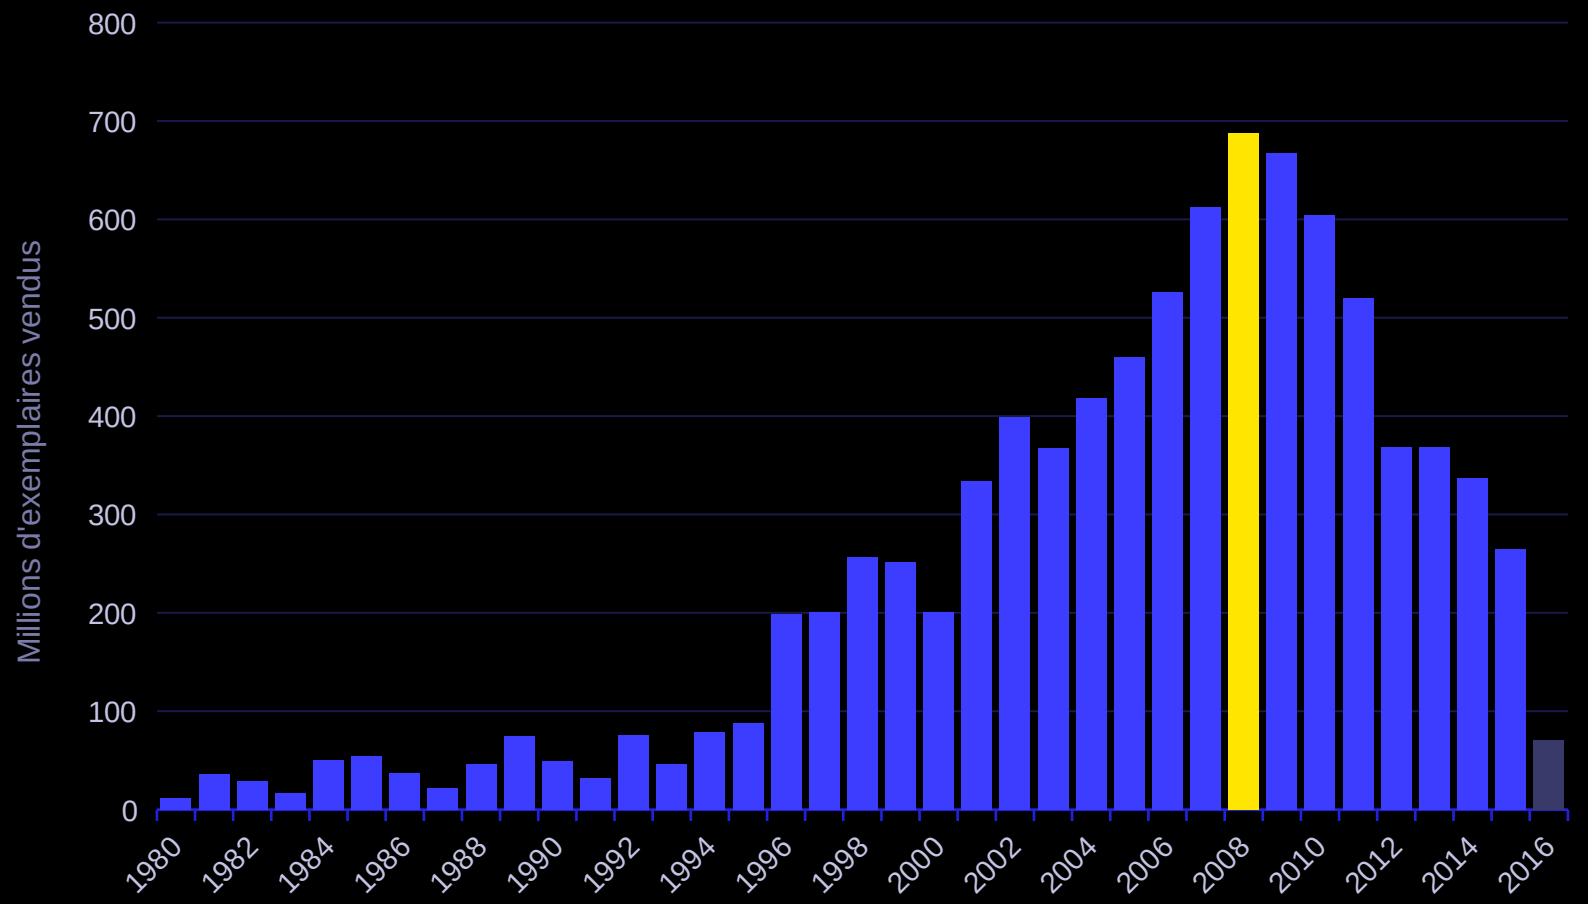
59% des ventes

0,17 M

ventes médianes d'un jeu : la plupart des titres vendent très peu

LEVEL 4 ➡ INSIGHT 2/4

2008 : l'âge d'or, puis le virage



688 M

d'exemplaires en 2008, le record

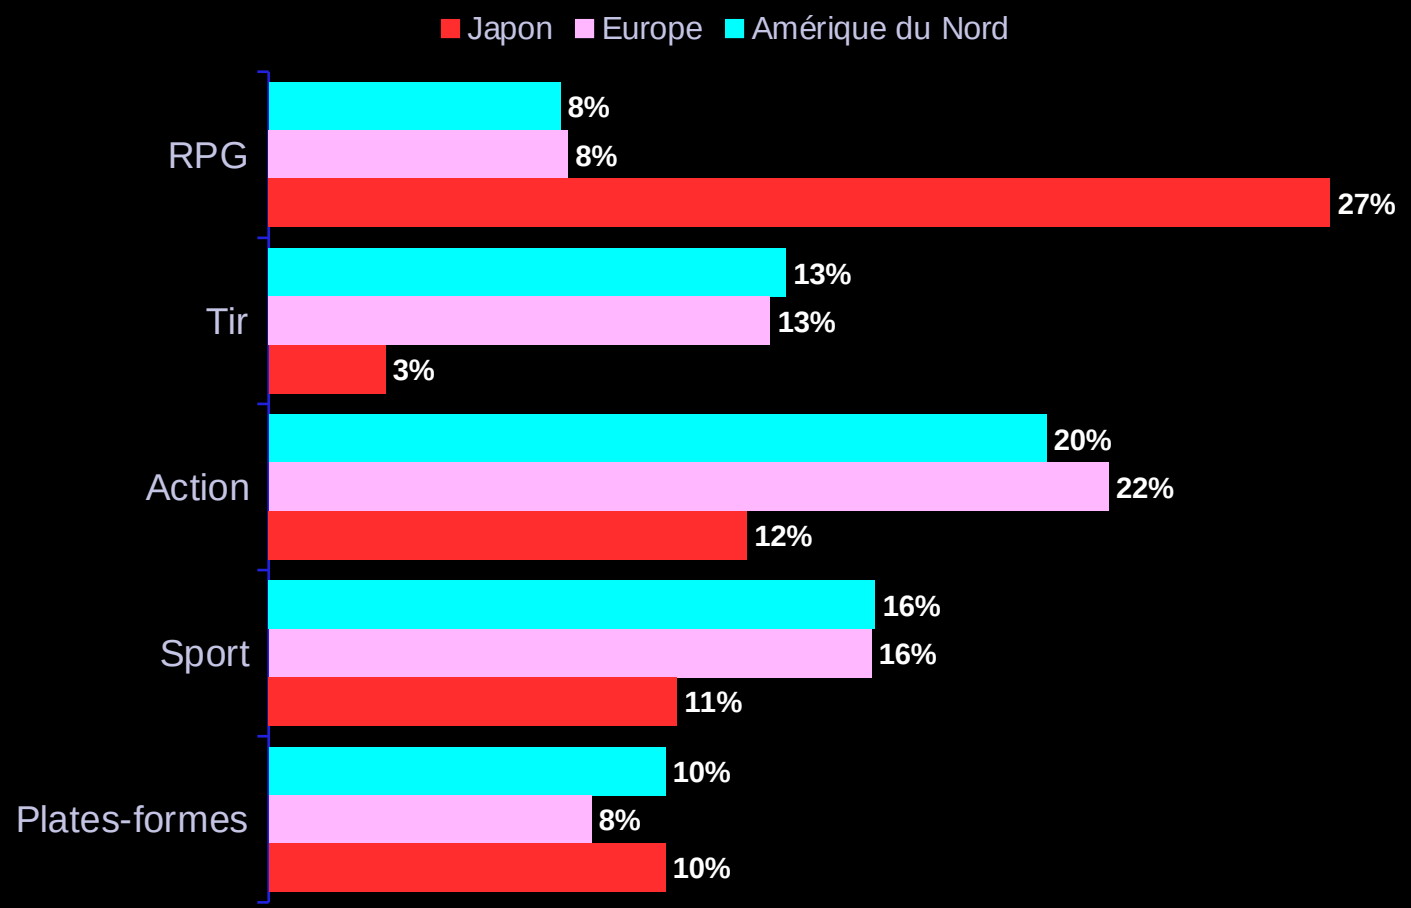
45%

des ventes viennent de la 7e génération : Wii, DS, X360, PS3, PSP

⚠ La baisse après 2009 reflète la montée du dématérialisé et du mobile, absents des données. 2016 est incomplète (gris).

LEVEL 4 ➡ INSIGHT 3/4

Deux mondes : Occident et Japon



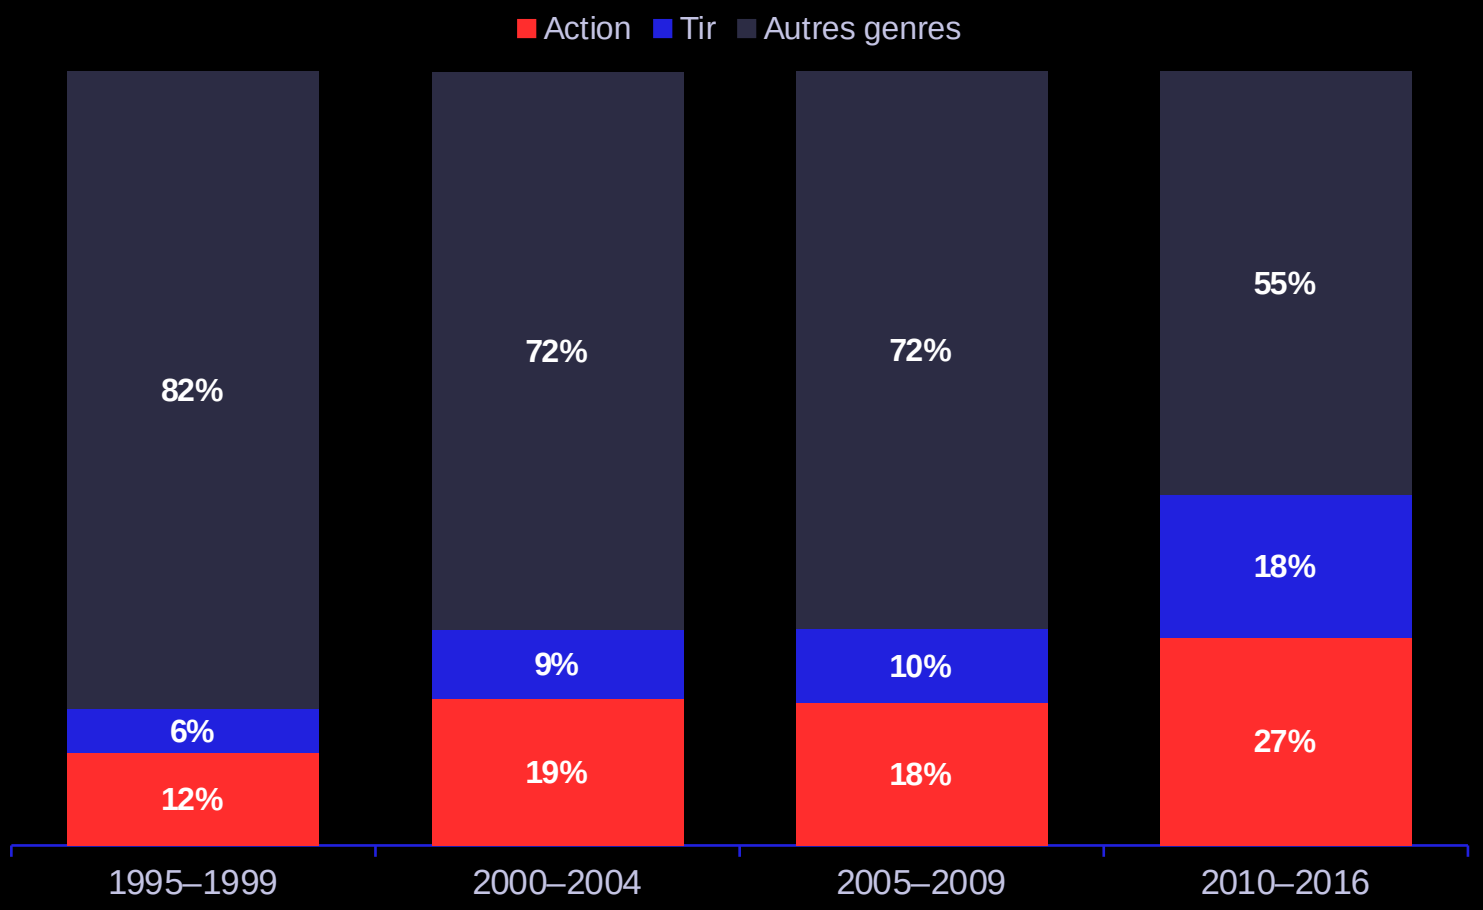
27% des ventes au Japon sont des RPG, contre 8 % en Occident

0,01 de divergence entre Amérique du Nord et Europe : des goûts quasi identiques

77% des jeux ultra-régionaux (outliers culturels) sont japonais

LEVEL 4 ➡ INSIGHT 4/4

L'Action et le Tir prennent tout



ACTION + TIR

18% ➡ 45%

des ventes, entre 1995–1999 et 2010–2016

PIEGE

Fréquent ≠ rentable

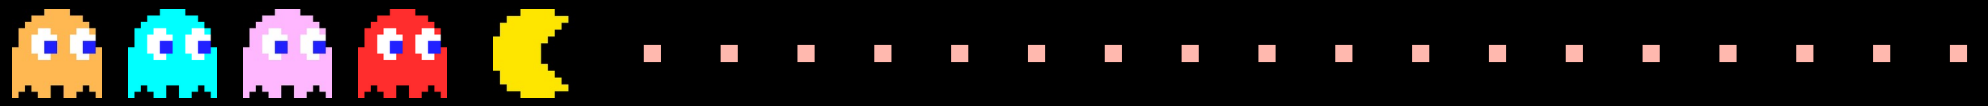
L'Aventure vend 3 fois moins que son poids dans le catalogue. Les Plates-formes chutent de 12 % à 5 % des ventes.



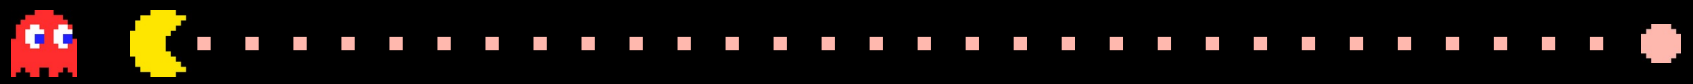
LEVEL 5

BOSS FINAL

Le Market Power Index des éditeurs

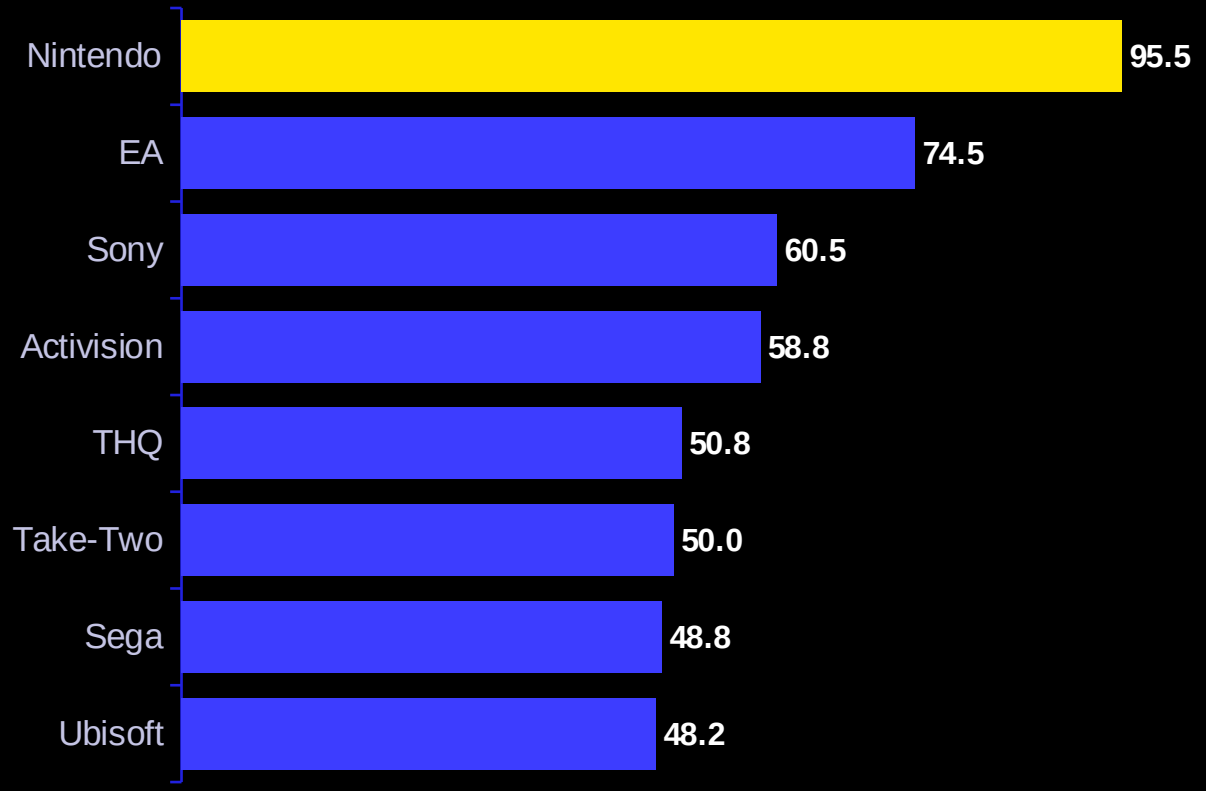


READY!



LEVEL 5 ➜ MARKET POWER INDEX

Nintendo, boss hors catégorie



Le pouvoir de marché récompense le taux de succès, pas la taille du catalogue.

BOSS : NINTENDO

95,5 /100

Part de marché	100
Leadership (> 30 %)	100
Diversité des genres	98
Constance régionale	86
Taux de hits	94

1er dans 100 % des pondérations testées · 20 % des ventes · 10/10 des jeux les plus vendus

BONUS ➜ NIVEAU SUIVANT

Angles morts et niveau suivant

ANGLES MORTS DE LA SOURCE

⚠ **Pas de ventes dématérialisées ni mobiles**

Steam, PSN, App Store : invisibles dans VGChartz

⚠ **Année 2016 incomplète**

le fichier s'arrête en cours d'année

⚠ **Régions parfois mal saisies**

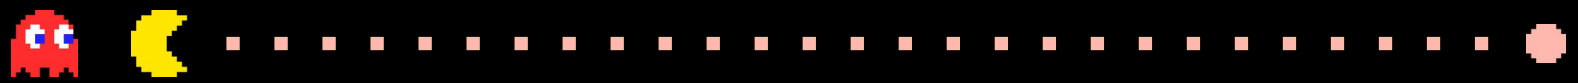
ex. ventes européennes de Gran Turismo 4 en « reste du monde »

NEXT LEVEL

BDD 2

Les ventes ne disent pas si un jeu est bon : une deuxième source pour le mesurer

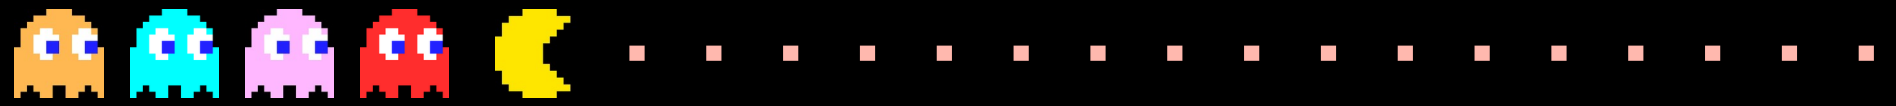
➜ ON CONTINUE !



DATA WRANGLING · PROJET FINAL

VENTES MONDIALES DE JEUX VIDEO

1980 – 2016 · 16 719 jeux · Partie 2 : la base Metacritic

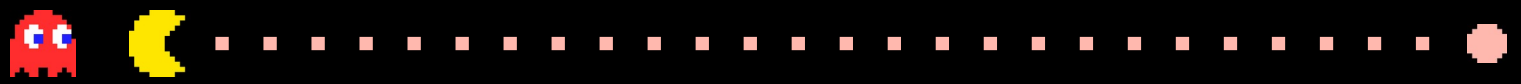


MODE COOP

1 EQUIPE · 2 BASES

CONTINUE ?

© 2026 PGE3 · 23 OCTOBRE



MENU → CHOISIS TON NIVEAU

Notre parcours

LEVEL 1



MISSION

La 2e source

LEVEL 2



NETTOYAGE

Nouveaux fantômes

LEVEL 3



JOINTURE

Relier 2 bases

LEVEL 4



INSIGHTS

4 découvertes

LEVEL 5



BOSS

MPI + qualité

LEVEL 6



LIVE DEMO

Les 2 bases



BONUS Le prix de la prestation avant / après, puis les limites et nos recommandations au client



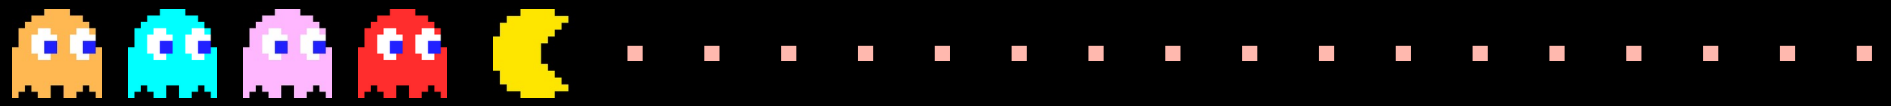




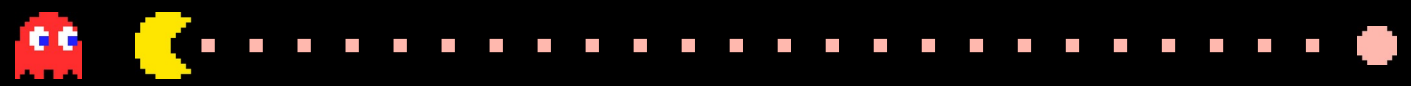
LEVEL 1

MISSION

Pourquoi une deuxième source ?



READY!



LEVEL 1 ➜ MISSION

La demande du client

QUETE : 2E SOURCE

Une bonne note fait-elle **vendre** ?

Les ventes disent combien un jeu s'est vendu, pas s'il était bon. La deuxième base apporte l'avis de la presse et des joueurs sur chaque jeu.

Source : Video Game Sales with Ratings (Kaggle, rush4ratio) · scraping Metacritic du 22/12/2016 · licence non précisée, usage pédagogique

16 719
lignes : un jeu sur une plateforme, comme vgsales

6
colonnes nouvelles : notes, nombre d'avis, studio, âge

51%
de notes presse manquantes dans le brut

99,7%
des jeux de vgsales retrouvés dans Metacritic

LEVEL 1 ➜ MISSION

Pourquoi cette base ?



Jeux vidéo, 1980-2016
la même période que nos ventes

Une clé commune
nom + plateforme + année

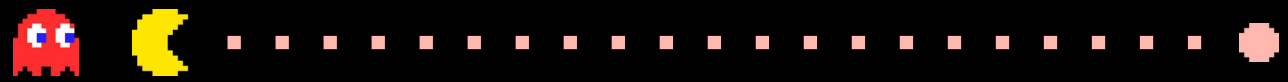
Une information nouvelle
notes, studio, classification d'âge

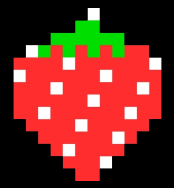
Une source citable
Kaggle, scraping daté du 22/12/2016

FICHE DE JEU

Grand Theft Auto V · PS3 · 2013

BASE 1	ventes	**21,40 M**
BASE 2	note presse	**97/100**
BASE 2	note joueurs	**8,2/10**
BASE 2	studio	**Rockstar North**
BASE 2	âge (ESRB)	**M : Adultes (17+)**





LEVEL 2

NETTOYAGE

Les nouveaux fantômes de la base 2

READY!

LEVEL 2 → NETTOYAGE

4 nouveaux fantômes

2 425
notes « tbd »

pas une note mais pas assez de votes : valeur manquante

51%
sans note presse

non imputées : quasi aucune note avant 2000

6
remakes mal notés

NFS Most Wanted 2005 = 2012 : note retirée plutôt que fausse

114
fiches fusionnées

mêmes règles que la base 1 : mêmes chiffres

16 447
jeux propres

16 719 → 16 447 lignes

8 061 notes presse · 7 528 notes joueurs

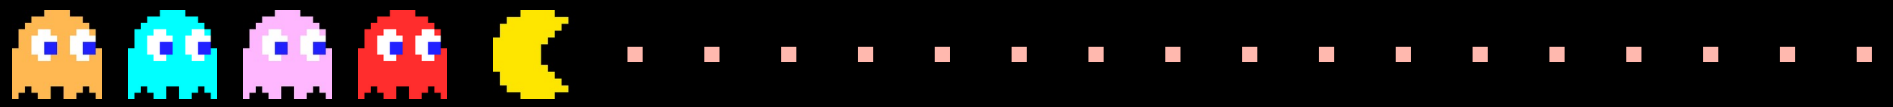
Mêmes règles, mêmes chiffres : le nettoyage de la base 1 est validé



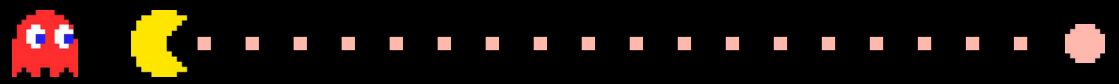
LEVEL 3

JOINTURE

Relier les ventes et les notes



READY!



LEVEL 3 ➡ JOINTURE

Une clé pour relier deux bases

NOM NORMALISE

WWE SmackDown! vs. RAW 2006

↓

wwesmackdownvsraw2006

+

PLATEFORME

PS2

↓

PS2

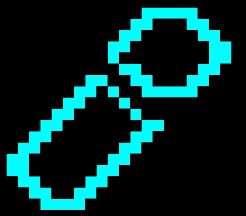
+

ANNEE

2005

↓

2005



99,7%

des jeux de vgsales retrouvent leur fiche Metacritic

44

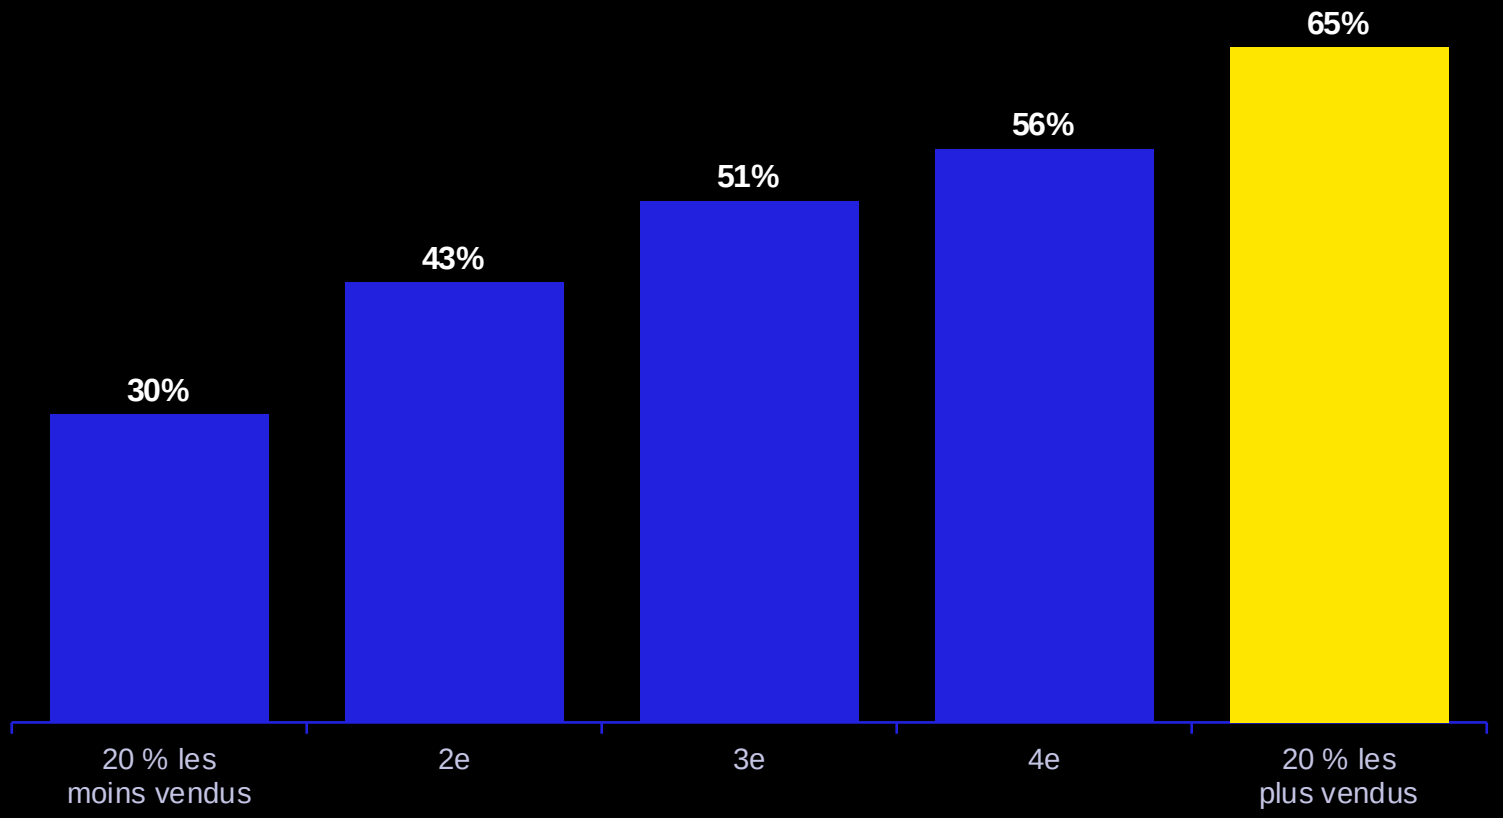
jeux sans partenaire : 0,56 M de ventes, négligeable

186

jeux aux ventes différentes entre les relevés : les ventes viennent toujours de la base 1

LEVEL 3 ➡ JOINTURE

Relié ≠ noté : le biais



Jeux classés par ventes mondiales, en 5 groupes de même taille

49% des jeux notés

mais

63% des ventes

BIAIS

Les notes décrivent surtout les jeux visibles, sortis entre 2000 et 2016



LEVEL 4

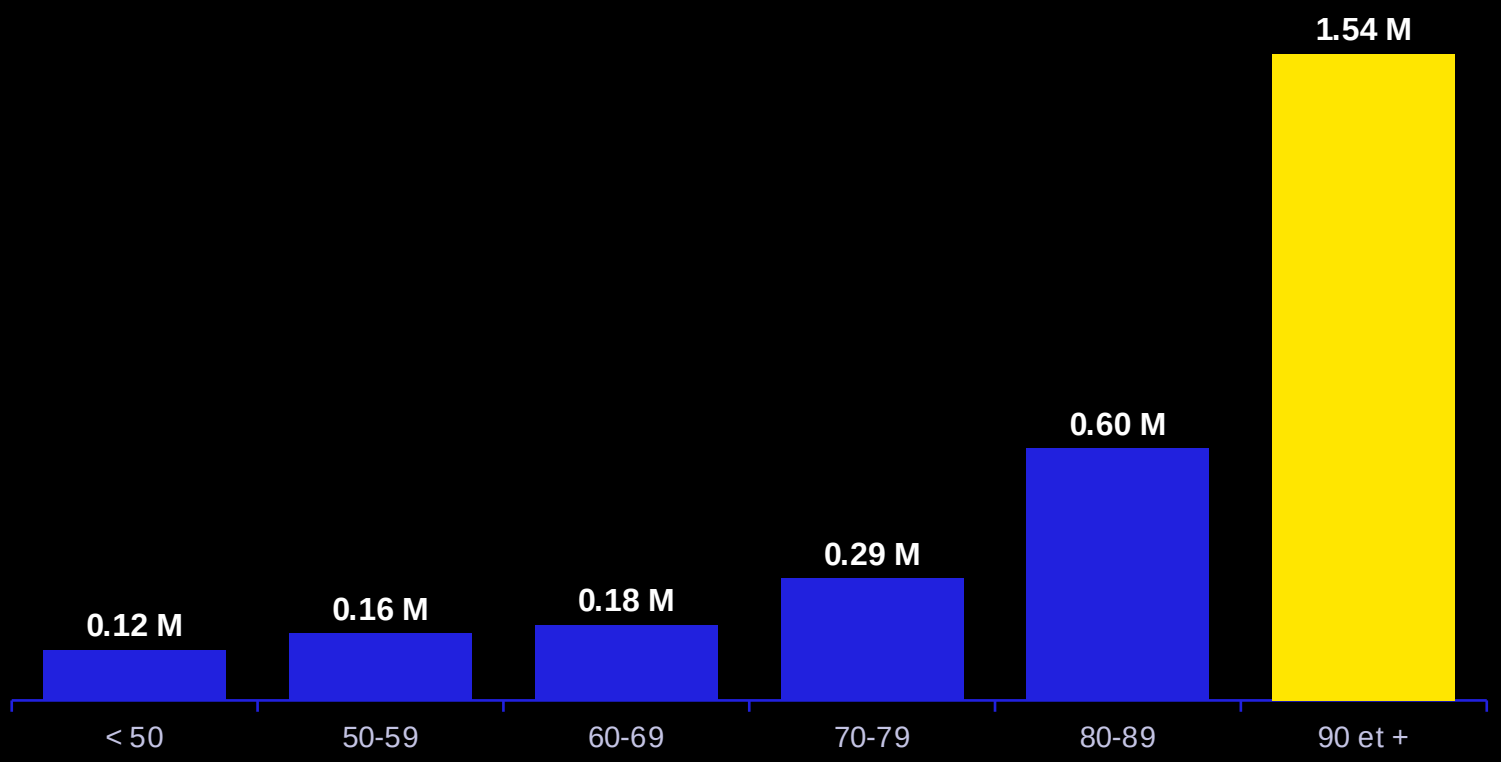
INSIGHTS

4 découvertes en croisant notes et ventes

READY!

LEVEL 4 ➡ INSIGHT 1/4

Bien noté = bien vendu ?



Note presse Metacritic (/100) · ventes mondiales médianes en millions

×13

de ventes médianes : 90 et + face à moins de 50

4%➡62%

de jeux à plus d'1 M

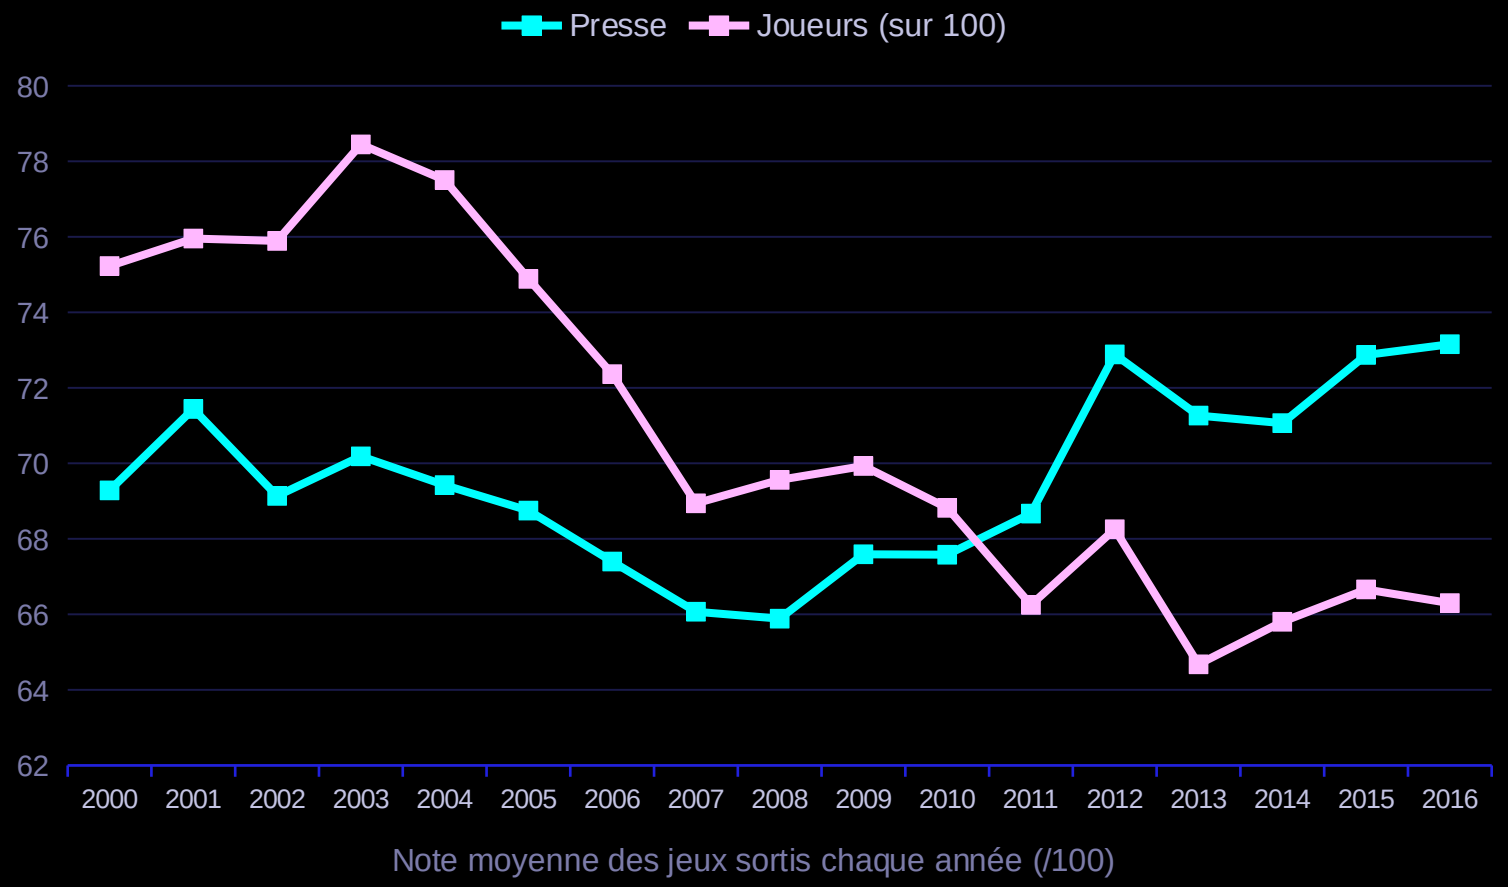
PIEGE

Lien ≠ cause

Wii Play : 58/100 et 29 M d'exemplaires

LEVEL 4 ➡ INSIGHT 2/4

Presse et joueurs divorcent



Note moyenne des jeux sortis chaque année (/100)

≈ 2010

les joueurs deviennent plus sévères que la presse

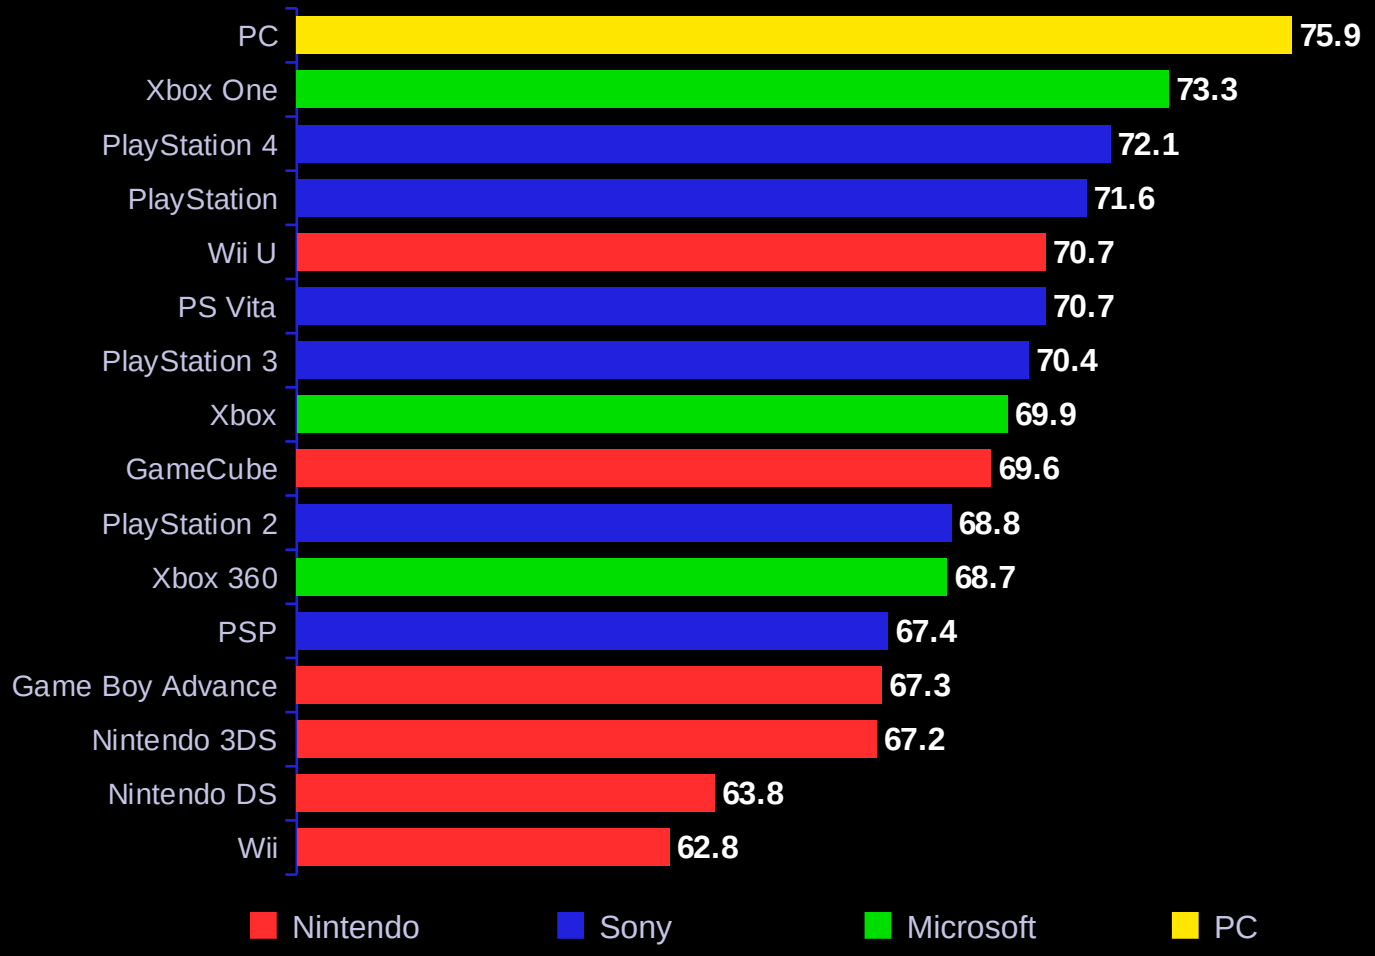
88 VS 32

Call of Duty MW3 (2011) : presse contre joueurs, sur plus de 5 000 votes

corrélation presse / joueurs : 0,58

LEVEL 4 ➡ INSIGHT 3/4

Wii et DS : vendues, pas notées



62,8

note moyenne des jeux Wii, la plus basse

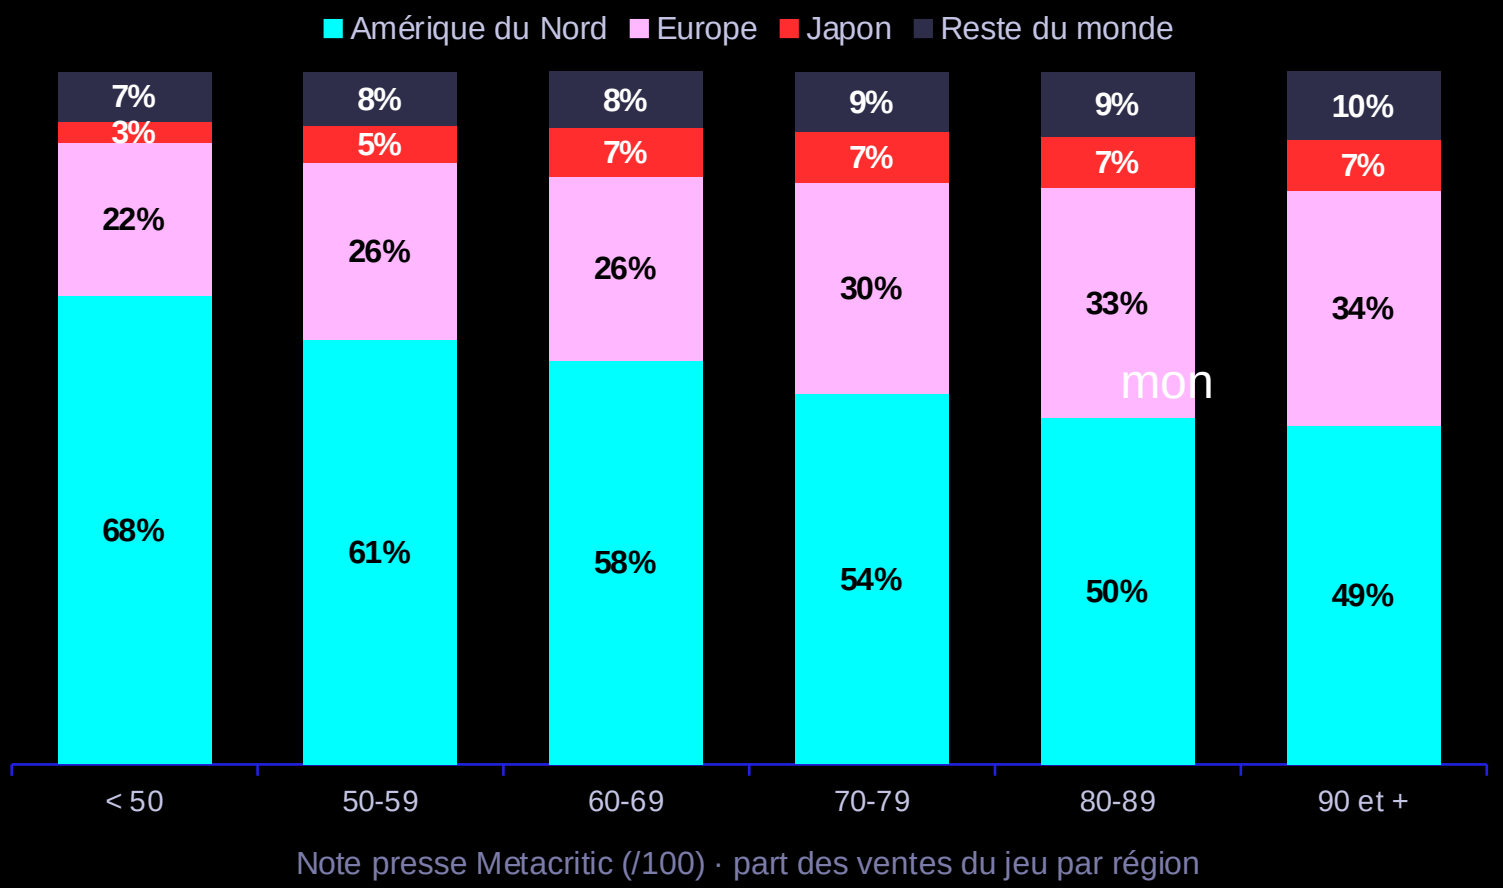
75,9 pour le PC

Ventes ≠ qualité

beaucoup de petits jeux familiaux à bas prix, mal notés

LEVEL 4 ➡ INSIGHT 4/4

L'Europe écoute la critique



Note presse Metacritic (/100) · part des ventes du jeu par région

AMERIQUE DU NORD

68% ➡ 49%

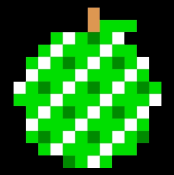
des ventes d'un jeu noté moins de 50, puis 90 et +

Europe 0,37

le marché le plus sensible aux notes

Japon 0,24

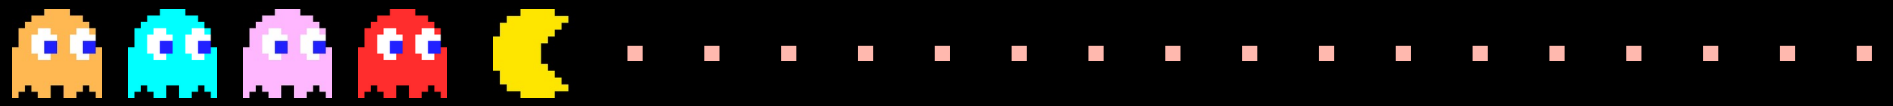
Metacritic = critiques occidentales



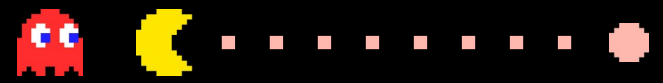
LEVEL 5

BOSS

Le Market Power Index, version 2



READY!



LEVEL 5 ➡ MARKET POWER INDEX

La qualité reclasse les éditeurs



RANG			AVANT	QUALITE
1	Nintendo	=	1e	79,9
2	Electronic Arts	=	2e	79,2
3	Sony	=	3e	83,5
4	Activision	=	4e	79,9
5	Take-Two	▲1	6e	86,5
6	Bethesda	▲3	9e	85,7
7	Microsoft	▲3	10e	82,0
8	Virgin	▲6	14e	86,8
9	Ubisoft	▼1	8e	75,6
10	THQ	▼5	5e	69,7
11	Sega	▼4	7e	71,8



MPI 2.0

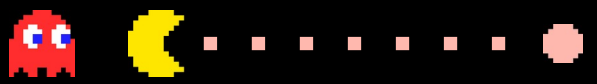
5 composantes de la partie 1 + la qualité perçue (note presse pondérée par les ventes)

Top 3 inchangé

▲ **Premium :** Bethesda, Microsoft, Virgin

▼ **Volume :** THQ, Sega

Deux modèles : beaucoup de jeux moyens, ou moins de jeux mais excellents



LEVEL 6

LIVE DEMO

INSERT COIN

Streamlit · 9 pages · les 2 bases

```
python run_app.py  →  localhost:8501
```

QUETE 1

Cliquer sur un jeu : GTA V

profil régional (base 1) + notes presse et joueurs (base 2)

QUETE 2

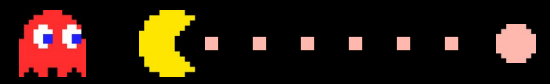
Régler les poids du MPI

puis la qualité perçue : Bethesda et Microsoft montent

QUETE 3

Filtrer période, genre, constructeur

toutes les pages suivent · années 80 : le biais Metacritic



BONUS → HIGH SCORE

Le prix de la prestation

AVANT

7 200 €

HT · 16 jours · ventes seules

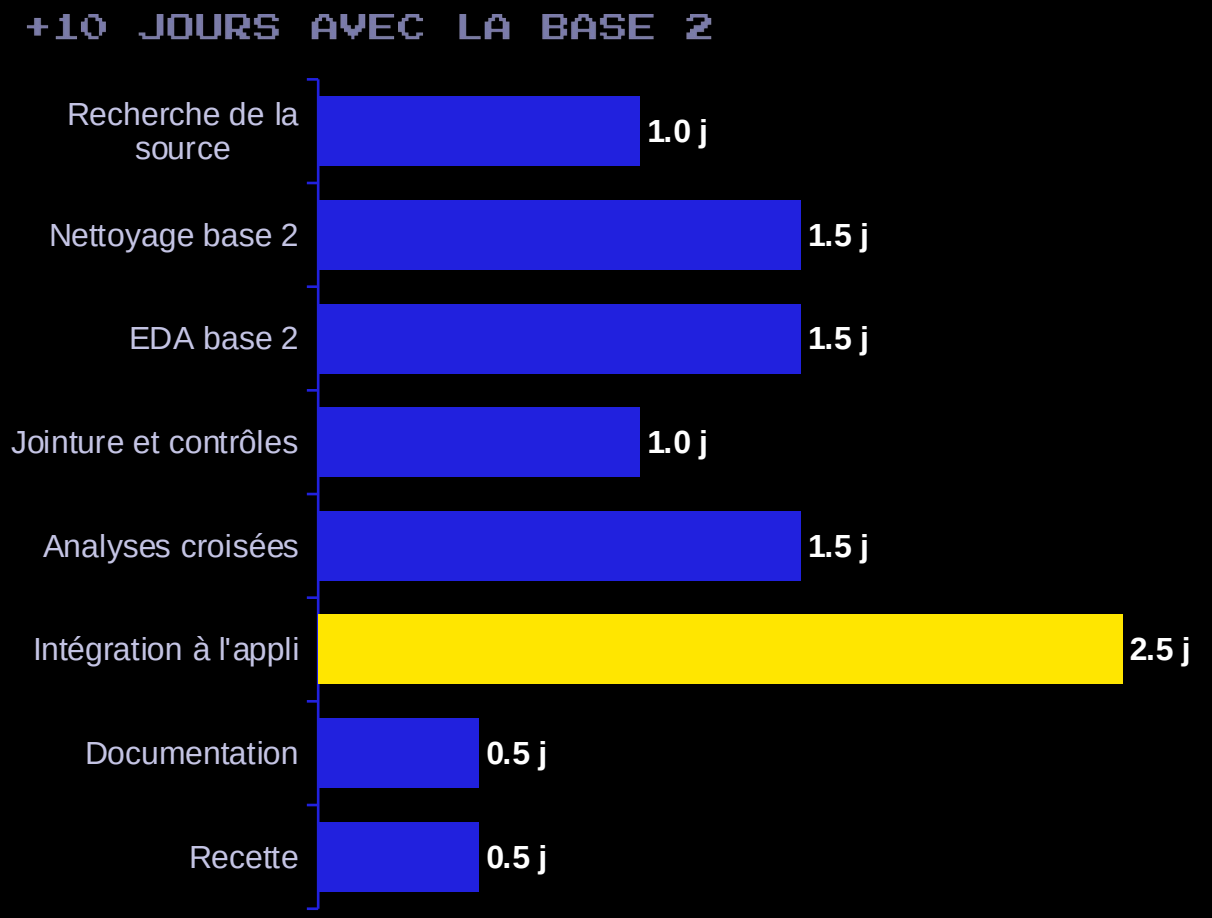
APRES

11 700 €

HT · 26 jours · ventes + notes

+4 500 € HT (+62,5 %)

TJM 450 € · réutilisation de l'existant



BONUS ➜ FIN DE PARTIE

Limites et recommandations



LIMITES



Notes partielles

49 % des jeux, surtout récents et visibles



Lien ≠ cause

le marketing peut expliquer note ET ventes



Source occidentale

le Japon est mal couvert par Metacritic

RECOMMANDATIONS



Miser sur la qualité

les jeux notés 80 et + font 53 % des ventes notées



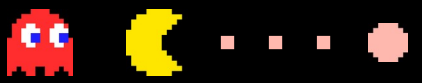
Viser l'Europe

le marché le plus sensible aux notes



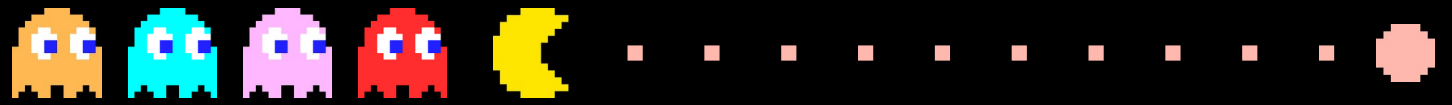
Prochaine source

les ventes dématérialisées (Steam) : l'angle mort de la partie 1



GAME OVER ?

NON : MISSION ACCOMPLIE



2 bases · 1 jointure · 1 appli de 9 pages · 38 figures

MERCI !

DES QUESTIONS ?

INSERT COIN TO CONTINUE

