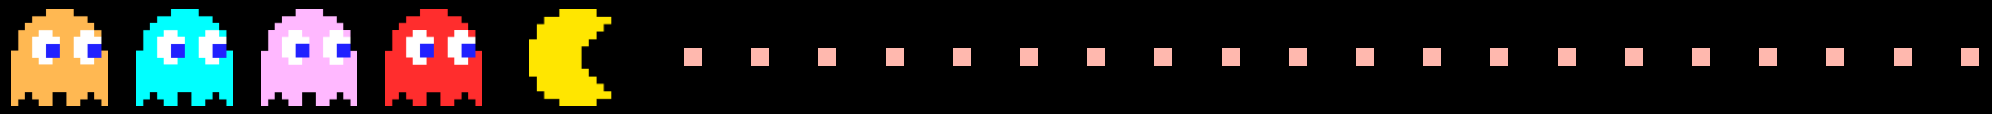
DATA WRANGLING · PROJET FINAL

VENTES MONDIALES DE JEUX VIDEO

1980 – 2016 · 16 598 jeux · Partie 1 : la base vgsales

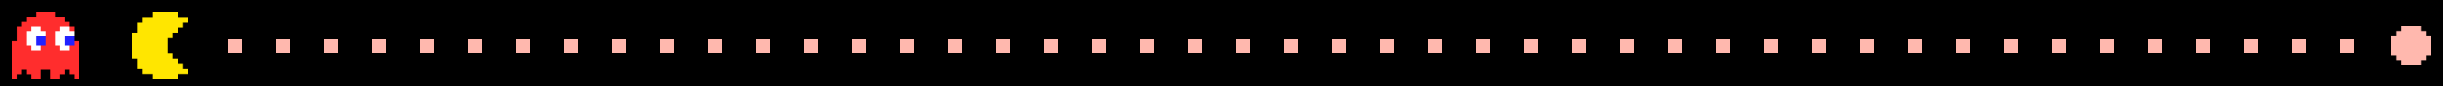


PLAYER 1

KHEIREDDINE BOUADI

PRESS START

© 2026 PGE3 · 23 OCTOBRE



MENU ➜ CHOISIS TON NIVEAU

Le parcours de ma partie

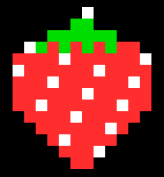
LEVEL 1



MISSION

Le contexte

LEVEL 2



PIPELINE

Du CSV à l'appli

LEVEL 3



NETTOYAGE

4 fantômes à manger

LEVEL 4



INSIGHTS

4 découvertes

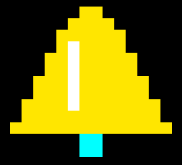
LEVEL 5



BOSS

Market Power Index

LEVEL 6



LIVE DEMO

L'appli en direct



BONUS Niveau suivant : la BDD 2, présentée par le reste de l'équipe





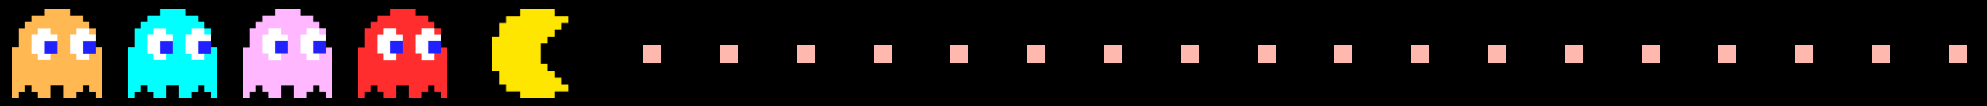




LEVEL 1

MISSION

Le contexte et la question de départ



READY!

LEVEL 1 → MISSION

Le contexte

ROLE : DATA ANALYST

Qu'est-ce qui fait vendre un jeu vidéo ?

Nettoyer les ventes mondiales de jeux, explorer les tendances et en tirer des insights métier.

Source : VGChartz · ventes en millions d'exemplaires · Amérique du Nord, Europe, Japon, reste du monde

16 598

jeux dans le fichier

37 ANS

de 1980 à 2016

31

plateformes, de l'Atari 2600 à la PS4

8,9 MD

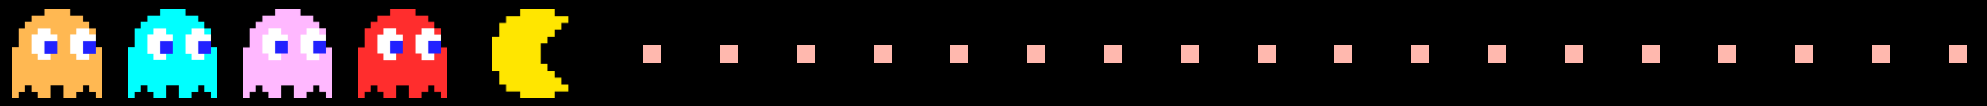
d'exemplaires vendus



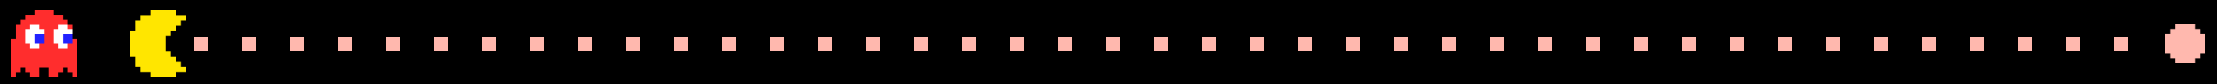
LEVEL 2

PIPELINE

Du fichier brut à l'appli interactive



READY!



LEVEL 2 ➜ PIPELINE

Du fichier brut à l'appli

01

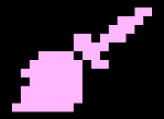


Données brutes

`vgsales.csv`

16 598 lignes

02



Nettoyage

`cleaning.py`

règles centralisées

03



Données propres

`vgsales_clean.csv`

16 326 jeux

04



Indicateurs

`indicators.py`

MPI · divergence

05



Restitution

`notebook + appli`

24 figures · 9 pages



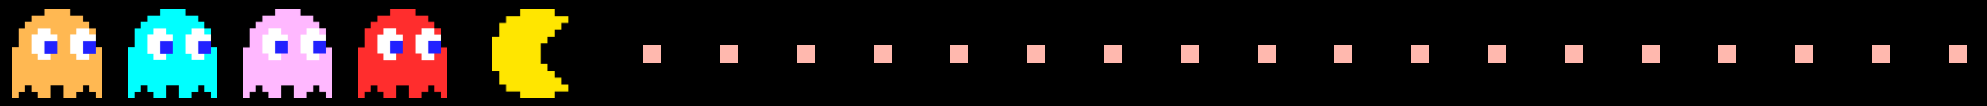
Un seul code de nettoyage pour le notebook ET l'appli. Un test (assert_frame_equal) garantit que les deux travaillent sur des données identiques.



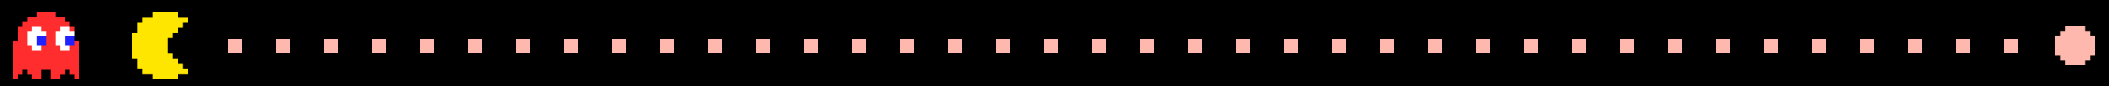
LEVEL 3

NETTOYAGE

4 fantômes cachés dans les données



READY!



LEVEL 3 ➜ NETTOYAGE

4 fantômes cachés dans les données

271
années manquantes

118 retrouvées grâce à une fiche jumelle, 153 supprimées

149
fiches « (JP sales) »

fusionnées : maximum par région, sans double comptage

10
dates impossibles

ex. un jeu DS daté de 1985 : 5 corrigées, 5 supprimées

261
éditeurs inconnus

58 vides + 203 « Unknown », regroupés en une seule catégorie

99,3%

des ventes conservées

16 598 → 16 326 jeux

11 239 titres uniques · 114 fiches fusionnées

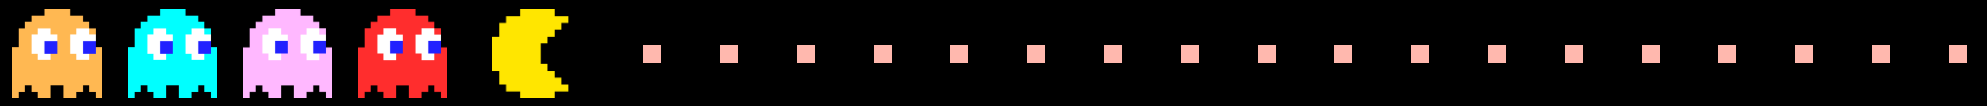
Chaque bug corrigé = un fantôme mangé



LEVEL 4

INSIGHTS

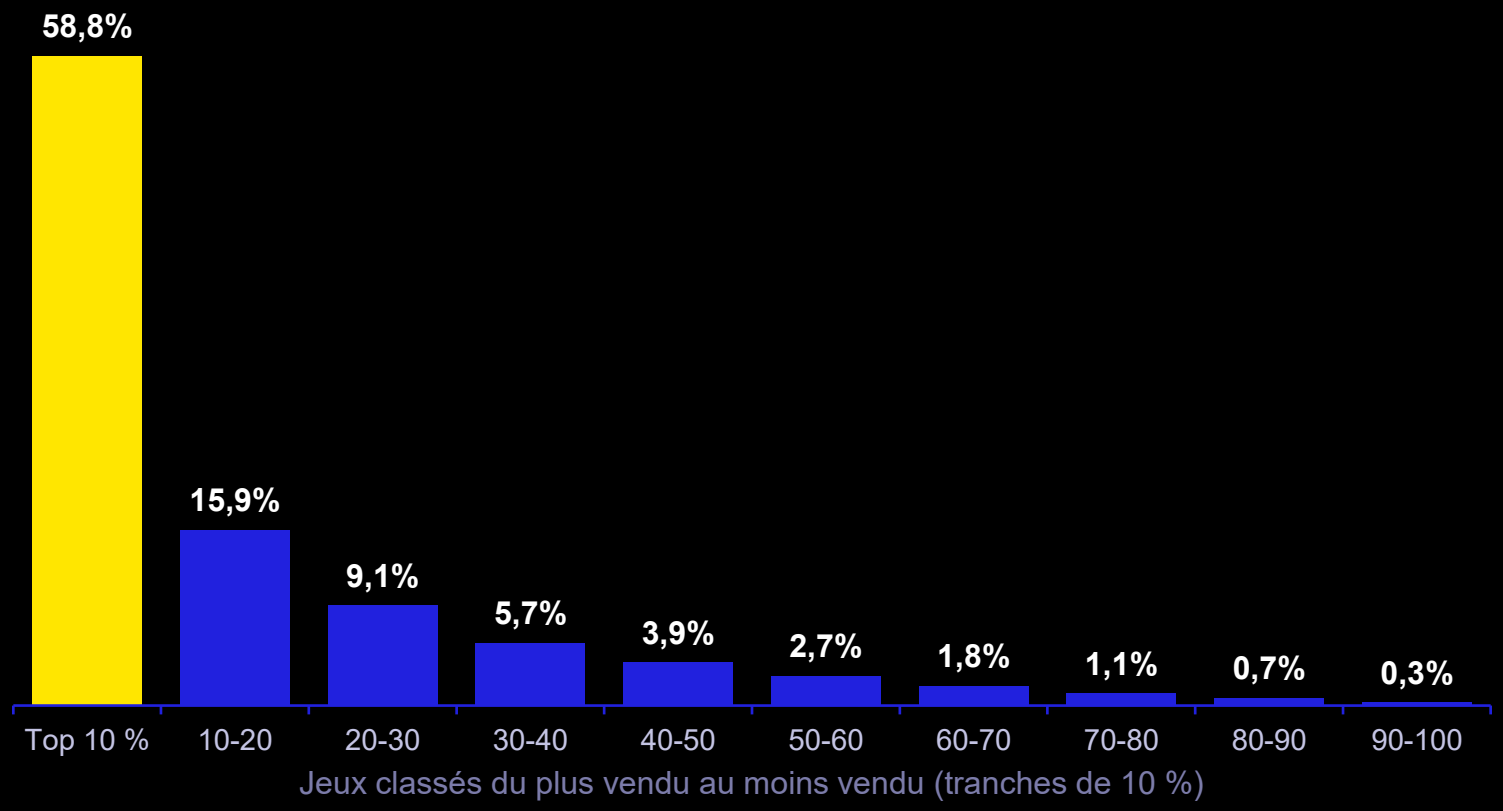
4 découvertes sur l'industrie du jeu vidéo



READY!

LEVEL 4 ➡ INSIGHT 1/4

Un marché de blockbusters



10% des jeux

réalisent

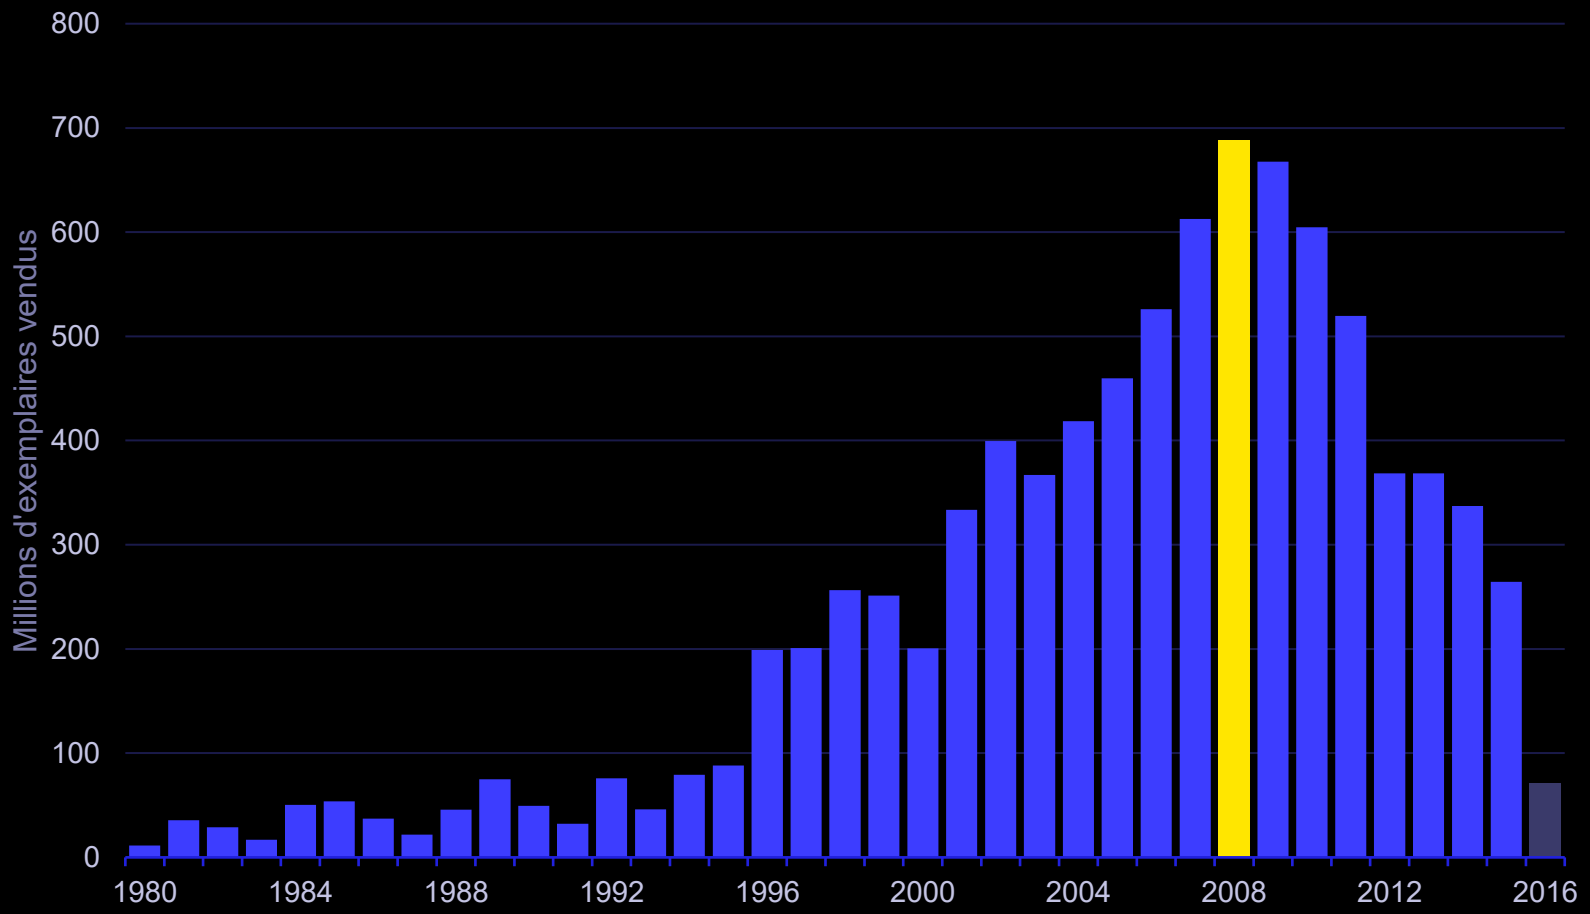
59% des ventes

0,17 M

ventes médianes d'un jeu : la plupart des titres vendent très peu

LEVEL 4 ➡ INSIGHT 2/4

2008 : l'âge d'or, puis le virage



688 M

d'exemplaires en 2008, le record

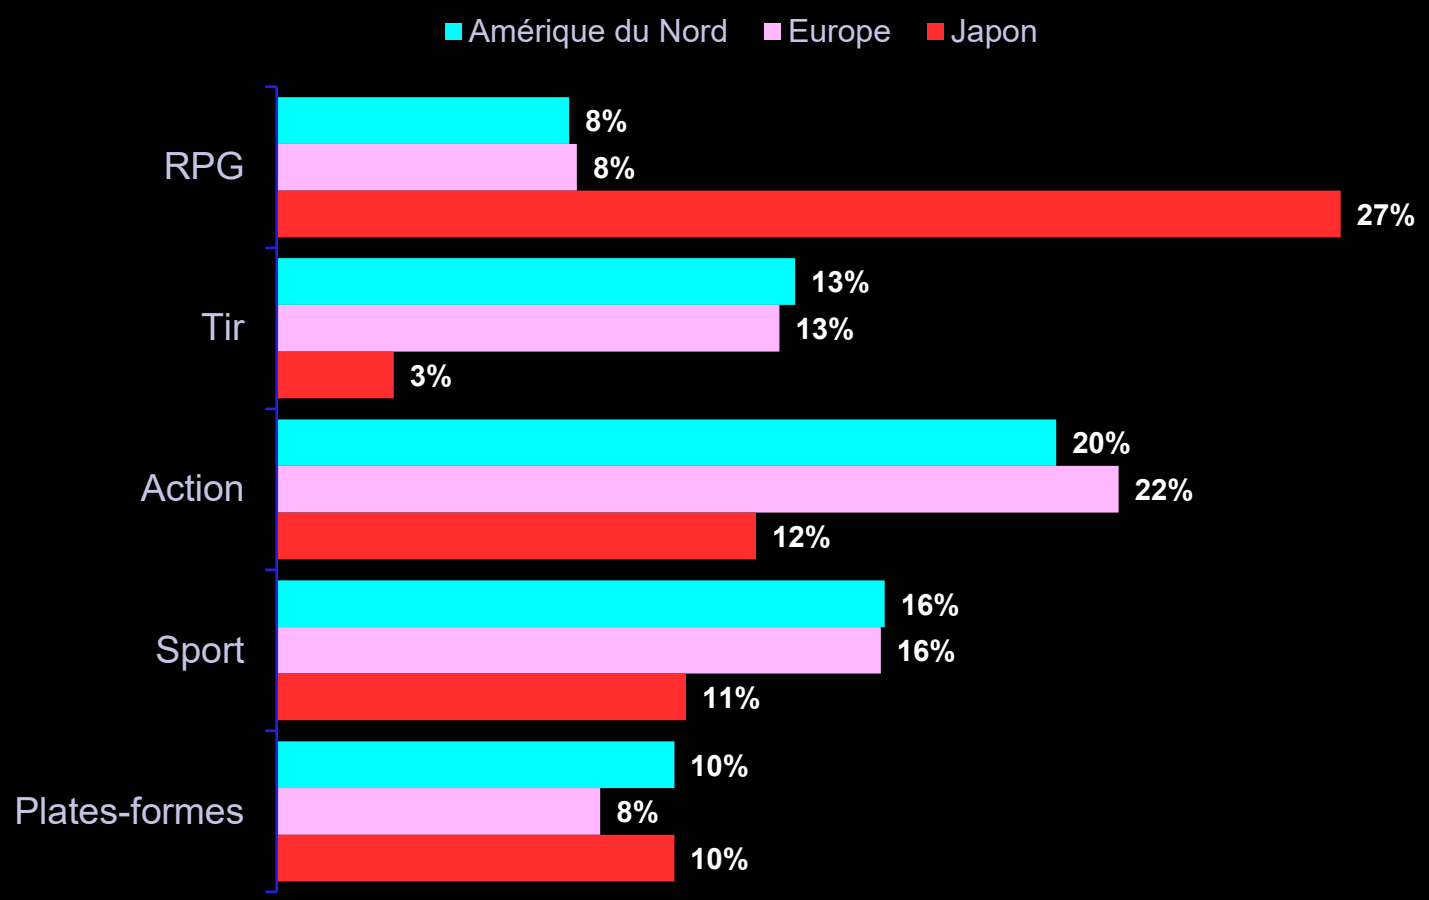
45%

des ventes viennent de la 7e génération : Wii, DS, X360, PS3, PSP

⚠ La baisse après 2009 reflète la montée du dématérialisé et du mobile, absents des données. 2016 est incomplète (gris).

LEVEL 4 ➡ INSIGHT 3/4

Deux mondes : Occident et Japon



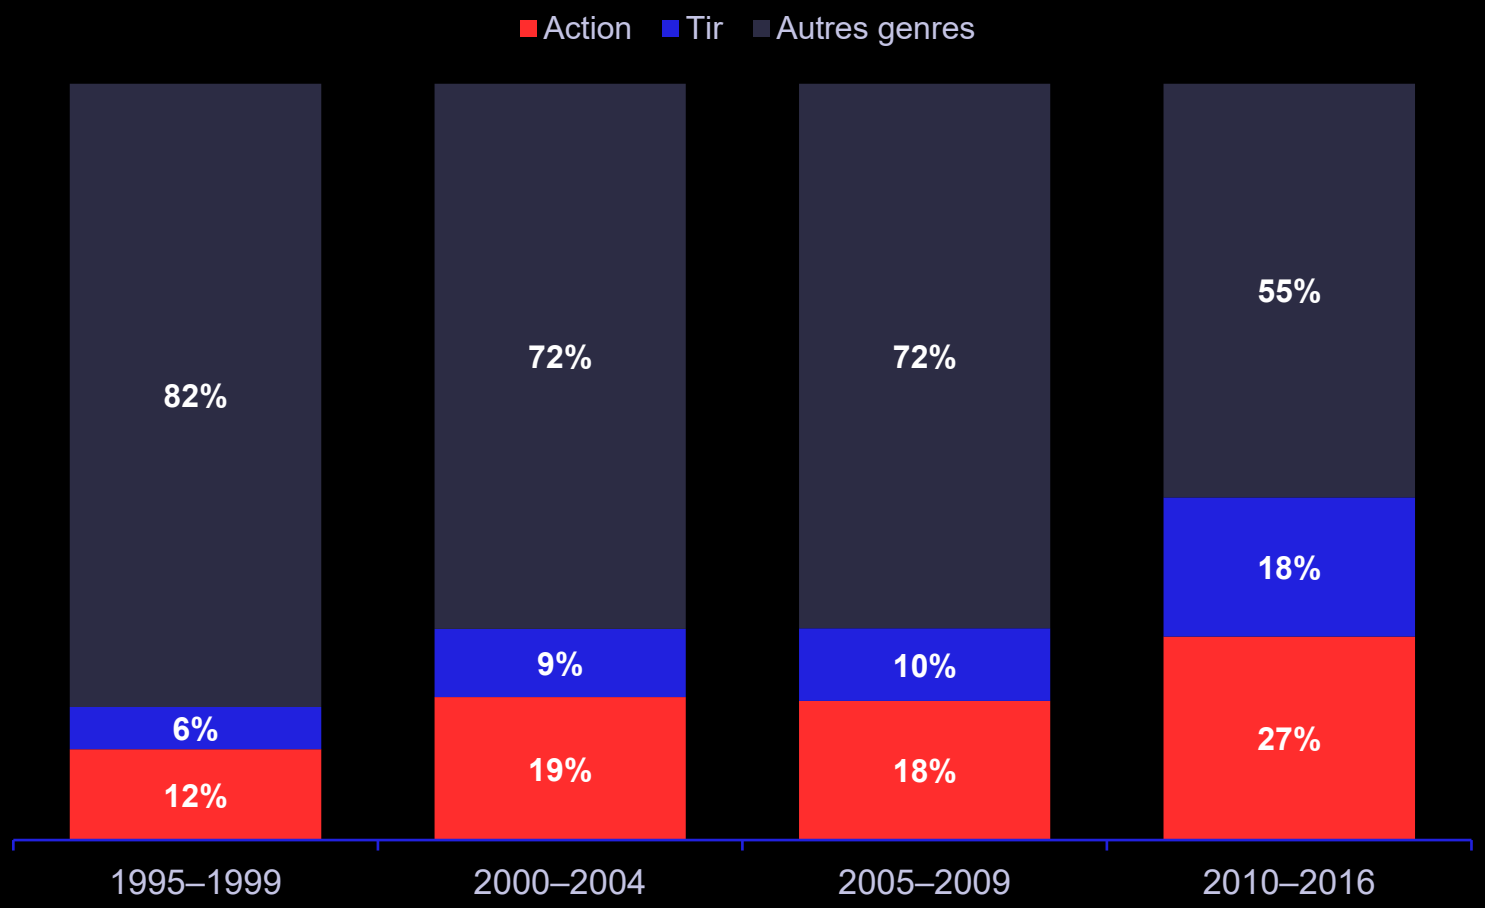
27% des ventes au Japon sont des RPG, contre 8 % en Occident

0,01 de divergence entre Amérique du Nord et Europe : des goûts quasi identiques

77% des jeux ultra-régionaux (outliers culturels) sont japonais

LEVEL 4 ➡ INSIGHT 4/4

L'Action et le Tir prennent tout



ACTION + TIR

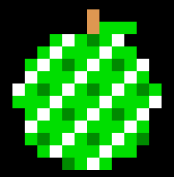
18% ➡ 45%

des ventes, entre 1995–1999 et 2010–2016

PIEGE

Fréquent ≠ rentable

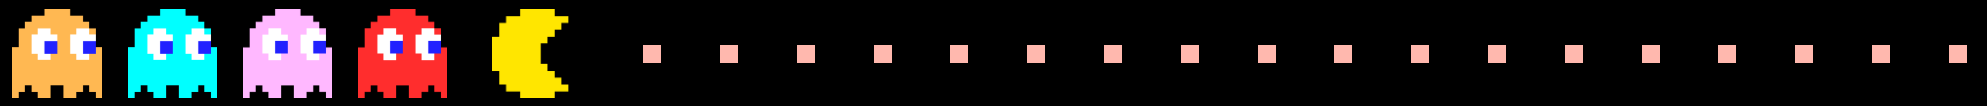
L'Aventure vend 3 fois moins que son poids dans le catalogue. Les Plates-formes chutent de 12 % à 5 % des ventes.



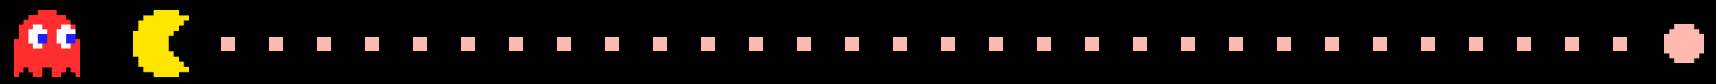
LEVEL 5

BOSS FINAL

Le Market Power Index des éditeurs

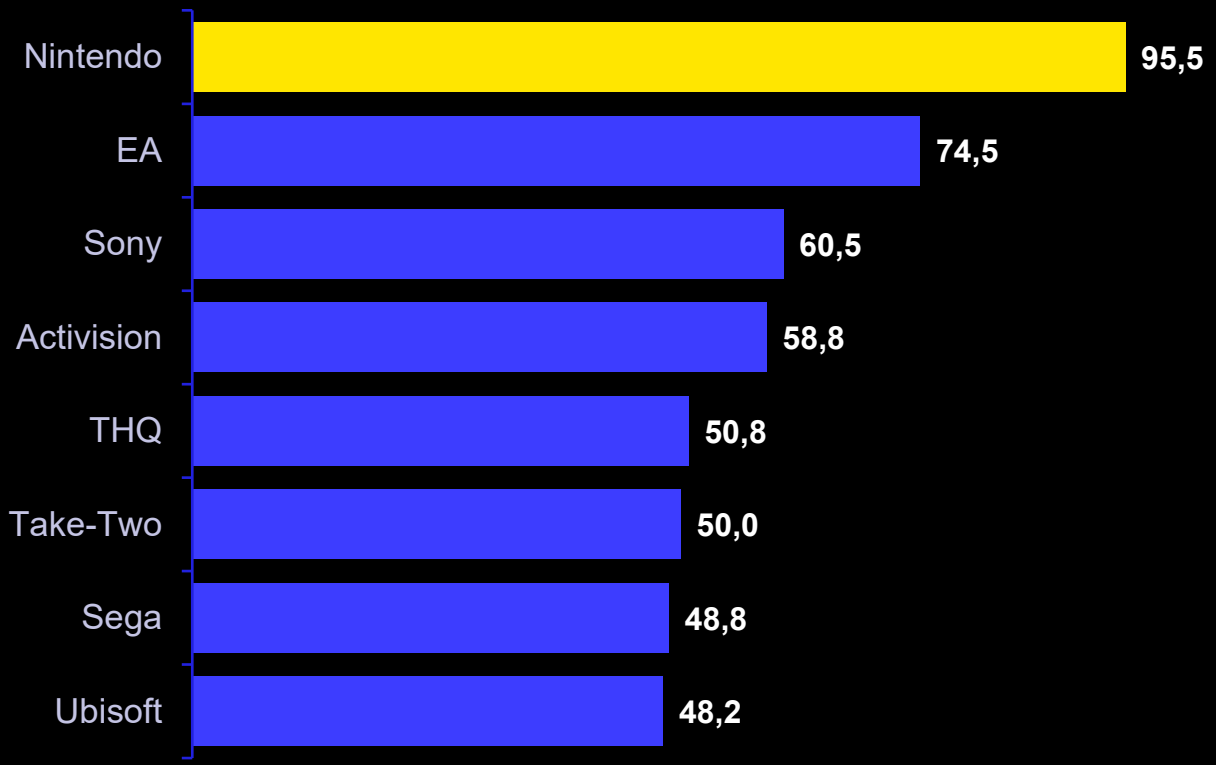


READY!



LEVEL 5 ➡ MARKET POWER INDEX

Nintendo, boss hors catégorie



Le pouvoir de marché récompense le taux de succès, pas la taille du catalogue.

BOSS : NINTENDO

95,5 /100

Part de marché	100
Leadership (> 30 %)	100
Diversité des genres	98
Constance régionale	86
Taux de hits	94

1er dans 100 % des pondérations testées · 20 % des ventes · 10/10 des jeux les plus vendus

LEVEL 6

LIVE DEMO

INSERT COIN

Interface Streamlit · 9 pages

`python run_app.py → localhost:8501`

QUETE 1

Régler les poids du MPI

le classement des éditeurs change en direct

QUETE 2

Cliquer sur un jeu

sa fiche et son profil régional s'ouvrent

QUETE 3

Filtrer période, genre, constructeur

toutes les pages suivent le filtre

BONUS → NIVEAU SUIVANT

Angles morts et niveau suivant

ANGLES MORTS DE LA SOURCE

⚠ **Pas de ventes dématérialisées ni mobiles**

Steam, PSN, App Store : invisibles dans VGChartz

⚠ **Année 2016 incomplète**

le fichier s'arrête en cours d'année

⚠ **Régions parfois mal saisies**

ex. ventes européennes de Gran Turismo 4 en « reste du monde »

NEXT LEVEL

BDD 2

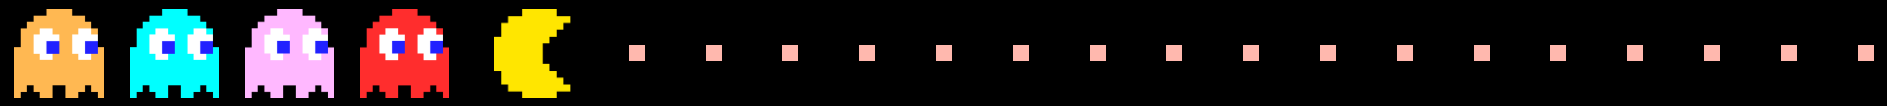
Les ventes ne disent pas si un jeu est bon : une deuxième source pour le mesurer

→ A VOUS !

DATA WRANGLING · PROJET FINAL

VENTES MONDIALES DE JEUX VIDEO

1980 – 2016 · 16 719 jeux · Partie 2 : la base Metacritic

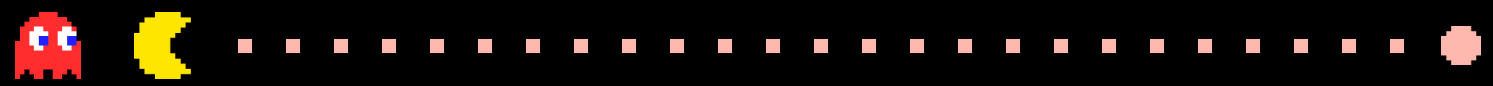


PLAYER 2

MOHAMED BEN AMOR

CONTINUE ?

© 2026 PGE3 · 23 OCTOBRE



MENU → CHOISIS TON NIVEAU

Le parcours de ma partie

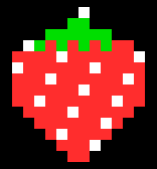
LEVEL 1



MISSION

La 2e source

LEVEL 2



NETTOYAGE

Nouveaux fantômes

LEVEL 3



JOINTURE

Relier 2 bases

LEVEL 4



INSIGHTS

4 découvertes

LEVEL 5



BOSS

MPI + qualité

LEVEL 6



LIVE DEMO

L'appli enrichie



BONUS Le prix de la prestation avant / après, puis les limites et nos recommandations au client



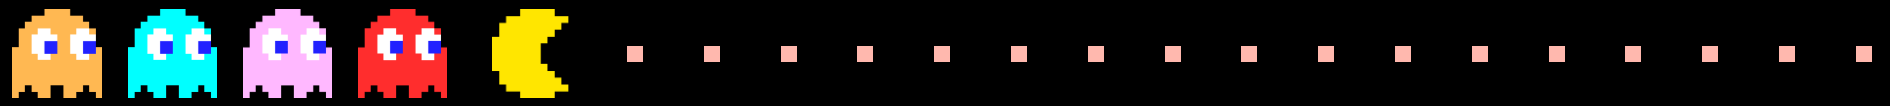




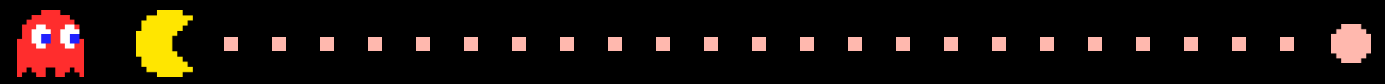
LEVEL 1

MISSION

Pourquoi une deuxième source ?



READY!



LEVEL 1 ➜ MISSION

La demande du client

QUETE : 2E SOURCE

Une bonne note fait-elle vendre ?

Les ventes disent combien un jeu s'est vendu, pas s'il était bon. La deuxième base apporte l'avis de la presse et des joueurs sur chaque jeu.

Source : Video Game Sales with Ratings (Kaggle, rush4ratio) · scraping Metacritic du 22/12/2016 · licence non précisée, usage pédagogique

16 719

lignes : un jeu sur une plateforme, comme vgsales

6

colonnes nouvelles : notes, nombre d'avis, studio, âge

51%

de notes presse manquantes dans le brut

99,7%

des jeux de vgsales retrouvés dans Metacritic

LEVEL 1 → MISSION

Pourquoi cette base ?

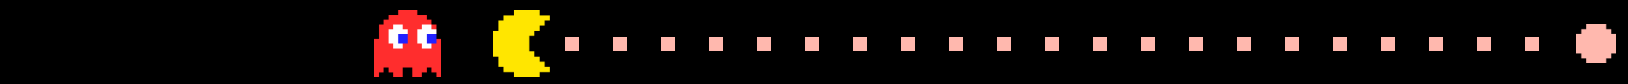


- **Jeux vidéo, 1980-2016**
  la même période que nos ventes
- **Une clé commune**
  nom + plateforme + année
- **Une information nouvelle**
  notes, studio, classification d'âge
- **Une source citable**
  Kaggle, scraping daté du 22/12/2016

FICHE DE JEU

Grand Theft Auto V · PS3 · 2013

BASE 1	ventes	21,40 M
BASE 2	note presse	97/100
BASE 2	note joueurs	8,2/10
BASE 2	studio	Rockstar North
BASE 2	âge (ESRB)	M : Adultes (17+)

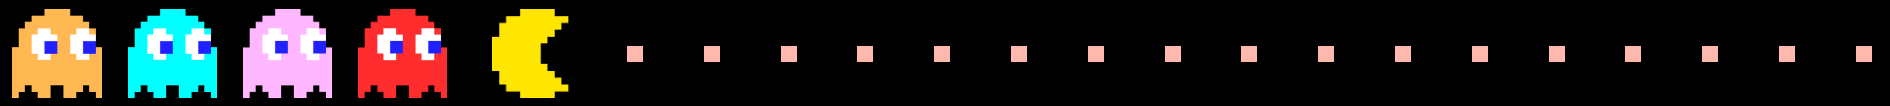




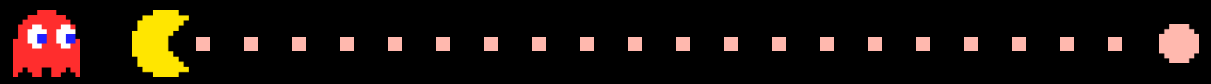
LEVEL 2

NETTOYAGE

Les nouveaux fantômes de la base 2



READY!



LEVEL 2 → NETTOYAGE

4 nouveaux fantômes

2 425

notes « tbd »

pas une note mais pas assez de votes : valeur manquante

51%

sans note presse

non imputées : quasi aucune note avant 2000

6

remakes mal notés

NFS Most Wanted 2005 = 2012 : note retirée plutôt que fausse

114

fiches fusionnées

mêmes règles que la base 1 : mêmes chiffres

16 447

jeux propres

16 719 → 16 447 lignes

8 061 notes presse · 7 528 notes joueurs

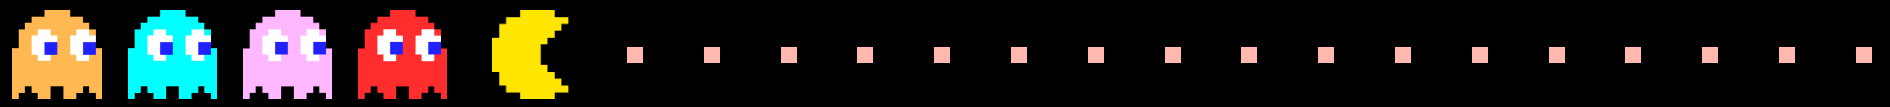
Mêmes règles, mêmes chiffres : le nettoyage de la base 1 est validé



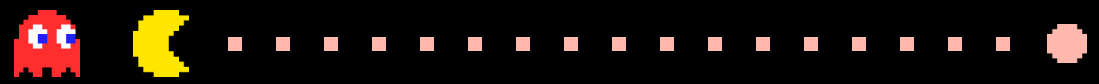
LEVEL 3

JOINTURE

Relier les ventes et les notes



READY!



LEVEL 3 ➔ JOINTURE

Une clé pour relier deux bases

NOM NORMALISE

WWE SmackDown! vs. RAW 2006

↓

wwesmackdownvsraw2006

+

PLATEFORME

PS2

↓

PS2

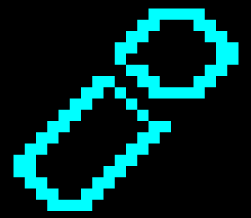
+

ANNEE

2005

↓

2005



99,7%

des jeux de vgsales retrouvent leur fiche Metacritic

44

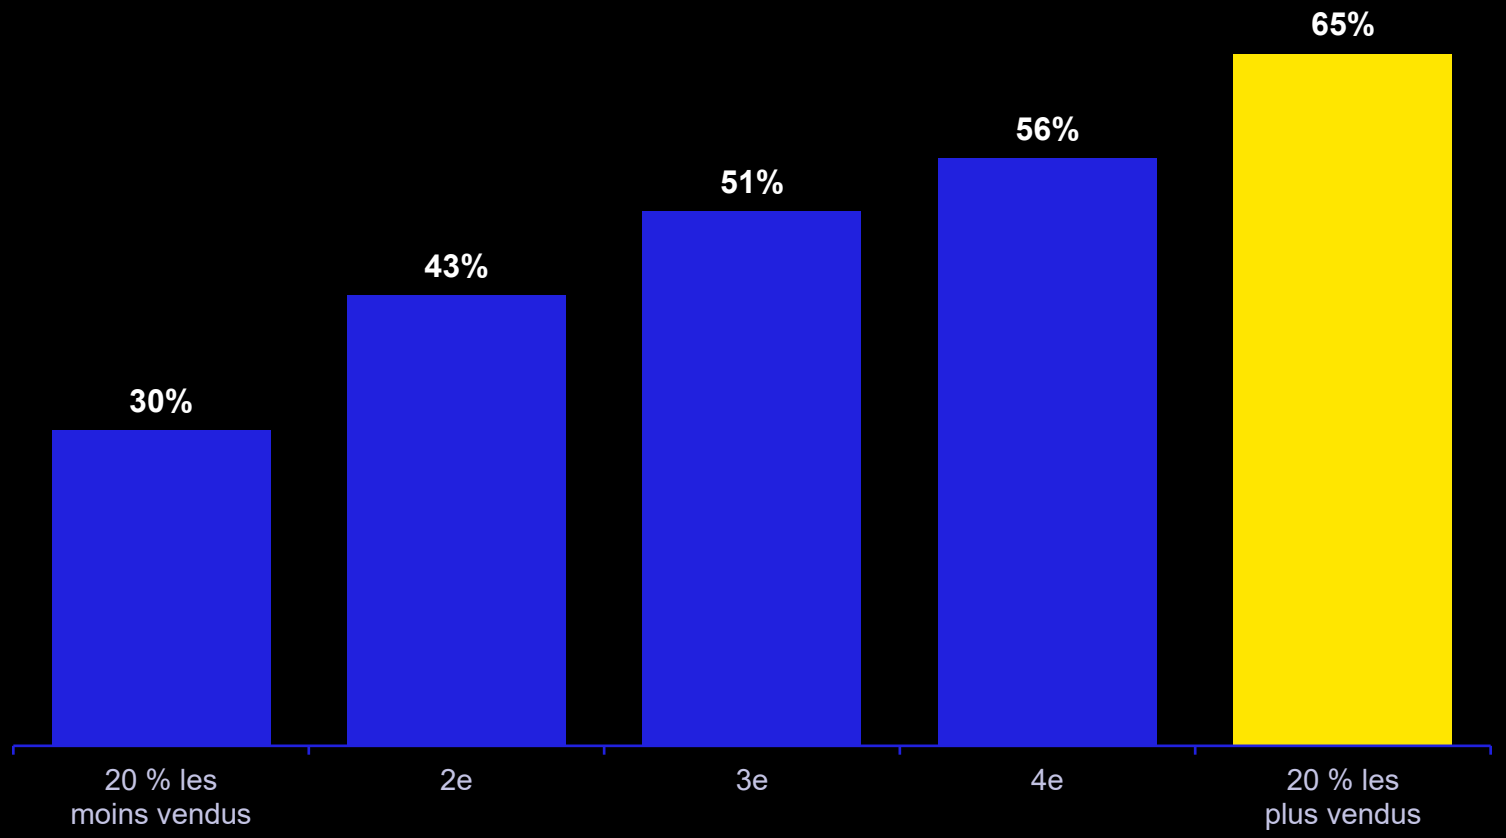
jeux sans partenaire : 0,56 M de ventes, négligeable

186

jeux aux ventes différentes entre les relevés : les ventes viennent toujours de la base 1

LEVEL 3 ➡ JOINTURE

Relié ≠ noté : le biais



49% des jeux notés

mais

63% des ventes

BIAIS

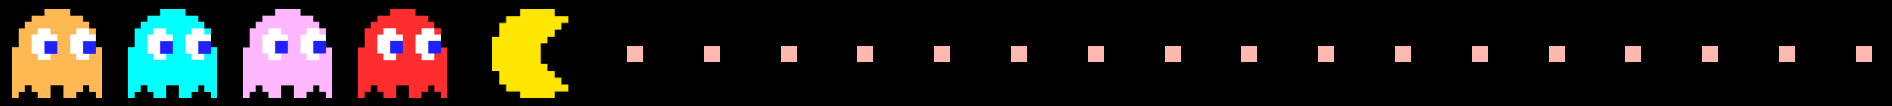
Les notes décrivent surtout les jeux visibles, sortis entre 2000 et 2016



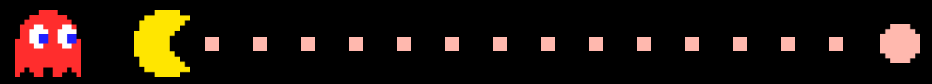
LEVEL 4

INSIGHTS

4 découvertes en croisant notes et ventes

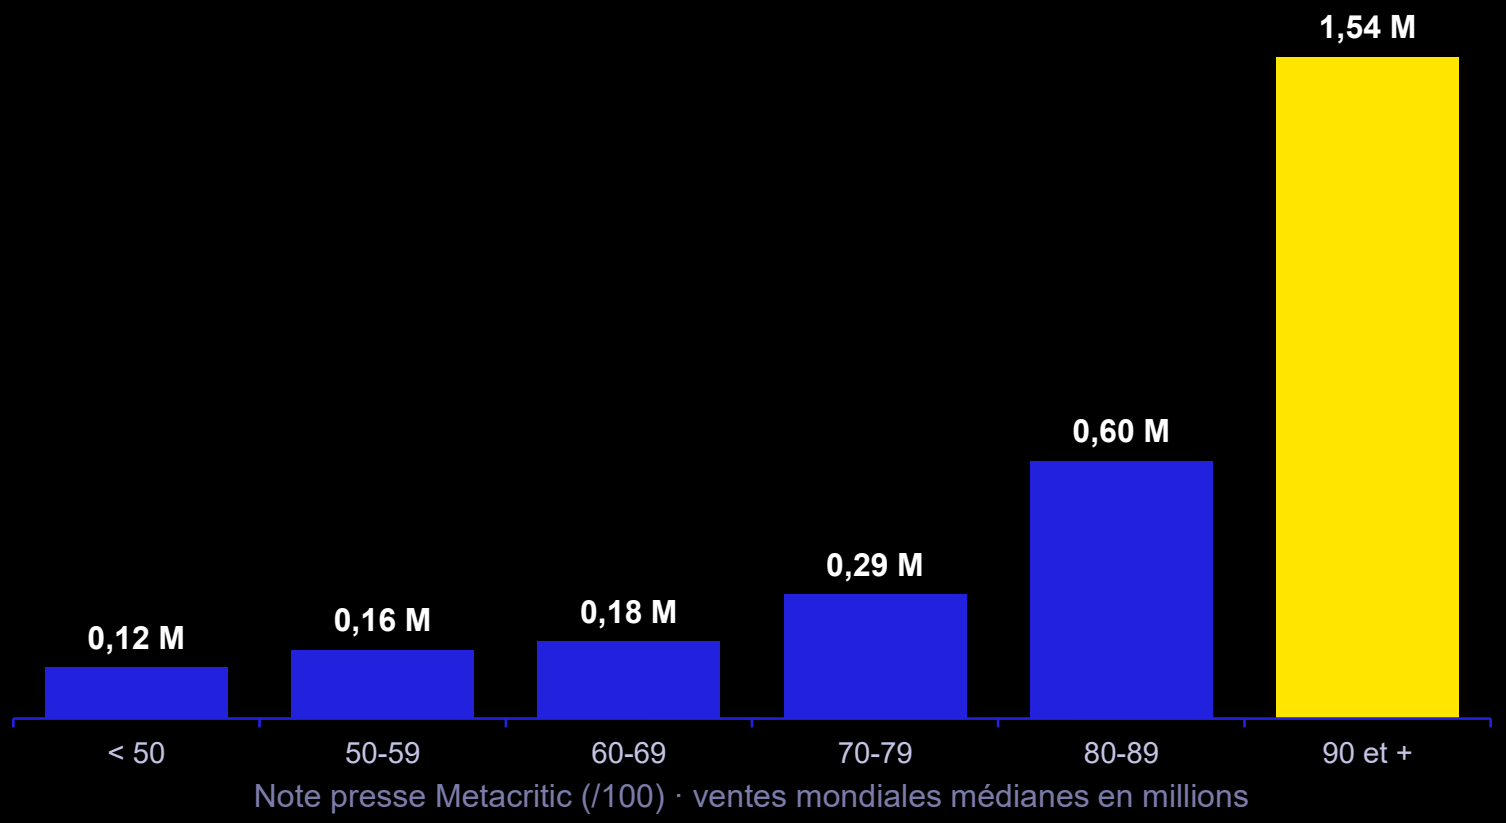


READY!



LEVEL 4 ➡ INSIGHT 1/4

Bien noté = bien vendu ?



x 13

de ventes médianes : 90 et + face à moins de 50

4% ➡ 62%

de jeux à plus d'1 M

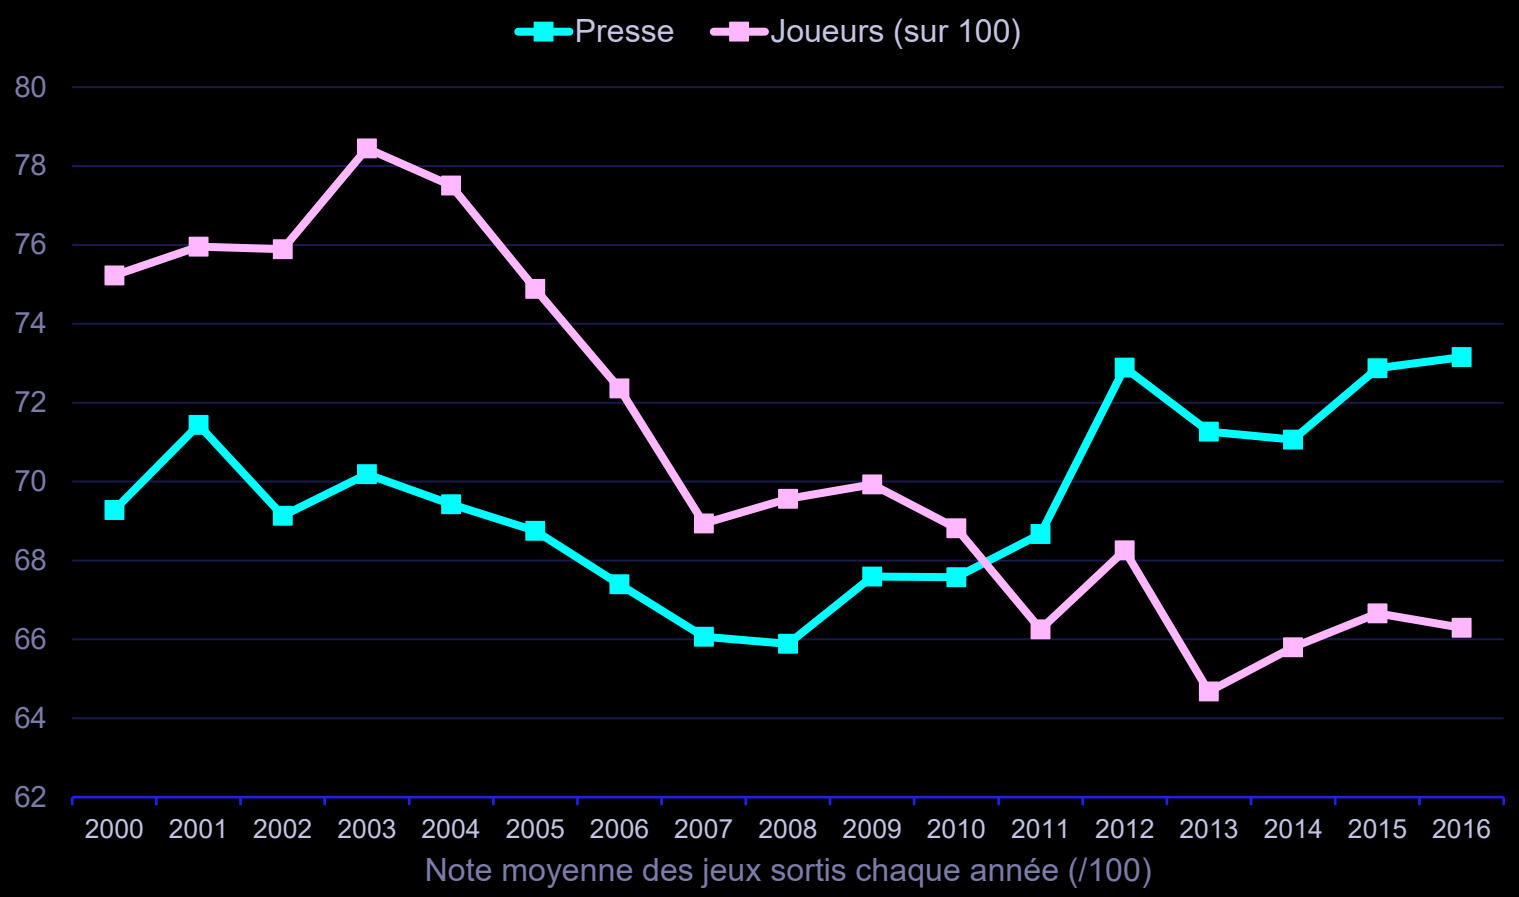
PIEGE

Lien ≠ cause

Wii Play : 58/100 et 29 M d'exemplaires

LEVEL 4 ➡ INSIGHT 2/4

Presse et joueurs divorcent



≈ 2010

les joueurs deviennent plus sévères que la presse

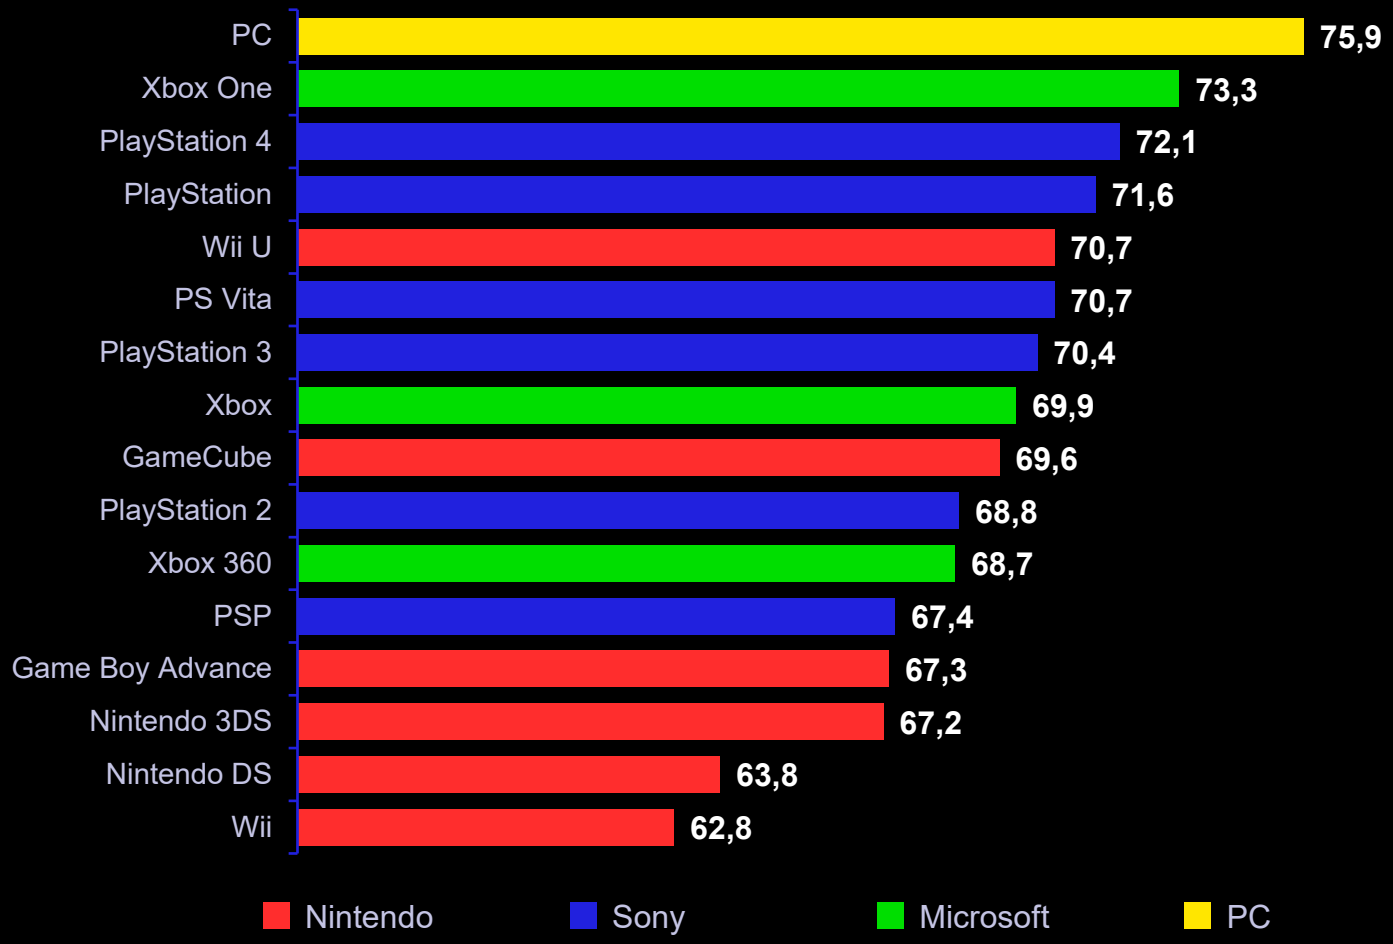
88 VS 32

Call of Duty MW3 (2011) : presse contre joueurs, sur plus de 5 000 votes

corrélation presse / joueurs : 0,58

LEVEL 4 ➡ INSIGHT 3/4

Wii et DS : vendues, pas notées



62,8

note moyenne des jeux Wii, la plus basse

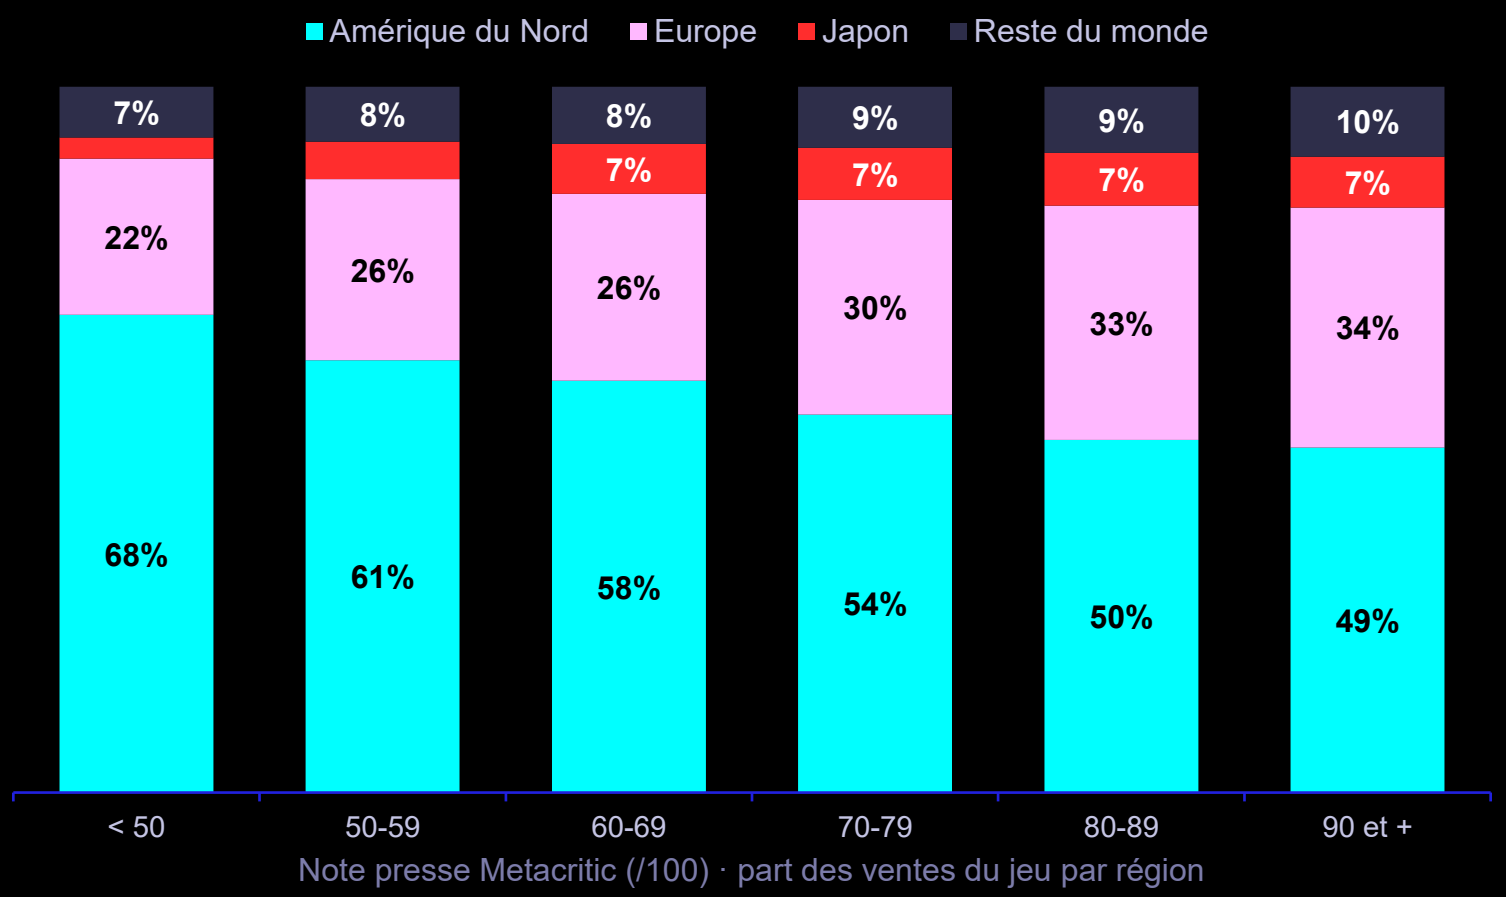
75,9 pour le PC

Ventes ≠ qualité

beaucoup de petits jeux familiaux à bas prix, mal notés

LEVEL 4 ➡ INSIGHT 4/4

L'Europe écoute la critique



Note presse Metacritic (/100) · part des ventes du jeu par région

AMERIQUE DU NORD

68% ➡ 49%

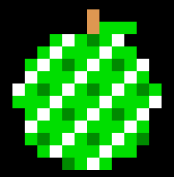
des ventes d'un jeu noté moins de 50, puis 90 et +

Europe 0,37

le marché le plus sensible aux notes

Japon 0,24

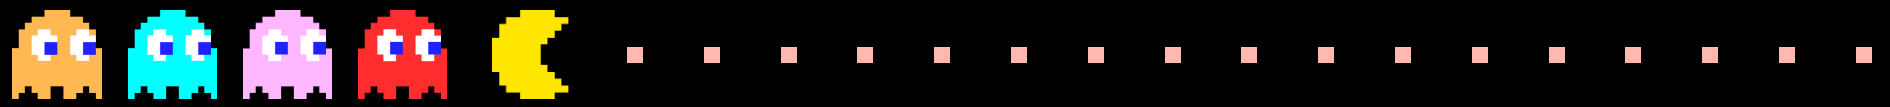
Metacritic = critiques occidentales



LEVEL 5

BOSS

Le Market Power Index, version 2



READY!

LEVEL 5 ➡ MARKET POWER INDEX

La qualité reclasse les éditeurs



RANG			AVANT	QUALITE
1	Nintendo	=	1e	79,9
2	Electronic Arts	=	2e	79,2
3	Sony	=	3e	83,5
4	Activision	=	4e	79,9
5	Take-Two	▲1	6e	86,5
6	Bethesda	▲3	9e	85,7
7	Microsoft	▲3	10e	82,0
8	Virgin	▲6	14e	86,8
9	Ubisoft	▼1	8e	75,6
10	THQ	▼5	5e	69,7
11	Sega	▼4	7e	71,8



MPI 2.0

5 composantes de la partie 1 + la qualité perçue (note presse pondérée par les ventes)

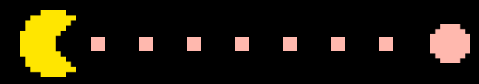
Top 3 inchangé

▲ **Premium :** Bethesda, Microsoft, Virgin

▼ **Volume :** THQ, Sega

Deux modèles : beaucoup de jeux moyens, ou moins de jeux mais excellents





LEVEL 6

LIVE DEMO

INSERT COIN

Interface Streamlit · 9 pages

```
python run_app.py  →  localhost:8501
```

QUETE 1

Page Notes Metacritic

clic sur « 90 et + », puis sur GTA V : ventes ET notes

QUETE 2

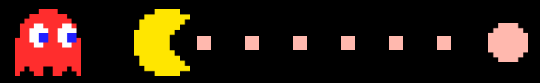
MPI : activer la qualité perçue

Bethesda et Microsoft montent, THQ et Sega descendent

QUETE 3

Filtrer les années 80

l'appli montre le biais : Metacritic ne note rien



BONUS → HIGH SCORE

Le prix de la prestation

AVANT

7 200 €

HT · 16 jours · ventes seules

APRES

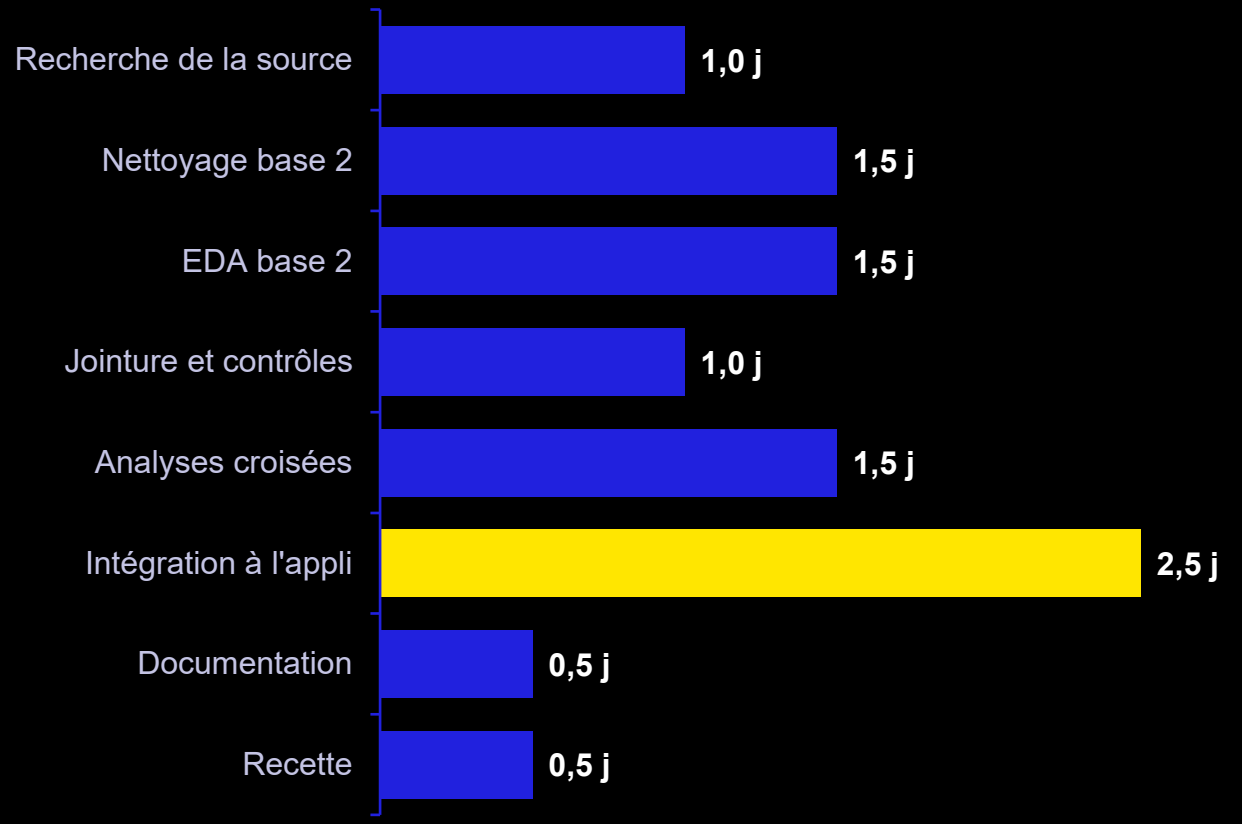
11 700 €

HT · 26 jours · ventes + notes

+4 500 € HT (+62,5 %)

TJM 450 € · réutilisation de l'existant

+10 JOURS AVEC LA BASE 2



BONUS ➜ FIN DE PARTIE

Limites et recommandations



LIMITES



Notes partielles

49 % des jeux, surtout récents et visibles



Lien ≠ cause

le marketing peut expliquer note ET ventes



Source occidentale

le Japon est mal couvert par Metacritic

RECOMMANDATIONS



Miser sur la qualité

les jeux notés 80 et + font 53 % des ventes notées



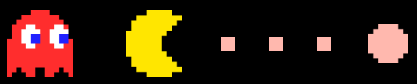
Viser l'Europe

le marché le plus sensible aux notes



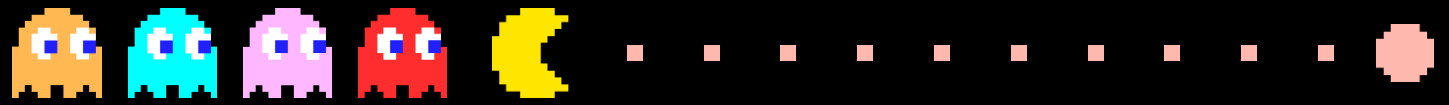
Prochaine source

les ventes dématérialisées (Steam) : l'angle mort de la partie 1



GAME OVER ?

NON : MISSION ACCOMPLIE



2 bases · 1 jointure · 1 appli de 9 pages · 38 figures

MERCI !

DES QUESTIONS ?

INSERT COIN TO CONTINUE

